



Universidad Internacional de La Rioja

Escuela Superior de Ingeniería y Tecnología

Máster Universitario en Ingeniería Matemática y
Computación

Estimación de Pose 6-DoF con *Transformers* y Modelos de
Difusión para Bin Picking Robótico

Trabajo fin de estudio presentado por:	Giocrisrai Godoy Bonillo y José Miguel Carrasco
Tipo de trabajo:	Tipo 2. Investigación con desarrollo práctico
Director/a:	Ivón Oristela Benítez González
Fecha:	Julio 2026

Resumen

Este Trabajo Fin de Máster aborda la estimación de pose 6-DoF para bin picking robótico, un problema abierto por las oclusiones, la falta de textura y las simetrías de las piezas. El objetivo es diseñar, integrar y validar un pipeline que une percepción y planificación a partir de dos paradigmas del aprendizaje profundo: FoundationPose, una arquitectura Transformer que estima la pose mediante atención cruzada 2D-3D, y Diffusion Policy, un modelo de difusión que genera trayectorias de agarre multimodales como ecuaciones diferenciales estocásticas inversas, articulados sobre un formalismo común de grupos de Lie $SE(3)/SO(3)$. La metodología combina la evaluación sobre los benchmarks BOP (YCB-Video y T-LESS) con la validación del ciclo completo en simulación (CoppeliaSim), y contrasta tres hipótesis (precisión, planificación multimodal y viabilidad temporal) mediante intervalos de confianza por bootstrap. Los resultados confirman una precisión competitiva con el estado del arte y una mejora respecto al baseline GDR-Net++, así como un ciclo end-to-end por debajo del umbral industrial de 10 s por instancia; la planificación por difusión resulta funcional, aunque su tiempo de muestreo no alcanza el umbral más estricto fijado. Como aporte de esta entrega, una capa de lenguaje natural permite seleccionar la pieza objetivo mediante instrucciones cotidianas, con un 100 % de acierto en un banco controlado. Se concluye que la integración es viable y reproducible sobre hardware accesible, y que la aportación reside en la integración matemática, el rigor metodológico y la reproducibilidad, no en una nueva arquitectura.

Palabras clave: estimación de pose 6-DoF, bin picking, FoundationPose, Diffusion Policy, Transformers, BOP Challenge.

Abstract

This Master's Thesis addresses 6-DoF pose estimation for robotic bin picking, an open problem due to occlusions, lack of texture and object symmetries. The aim is to design, integrate and validate a pipeline that couples perception and planning from two deep-learning paradigms: FoundationPose, a Transformer architecture that estimates pose through 2D-3D cross-attention, and Diffusion Policy, a diffusion model that generates multimodal grasp trajectories as reverse stochastic differential equations, articulated over a common Lie-group formalism on $SE(3)/SO(3)$. The methodology combines evaluation on the BOP benchmarks (YCB-Video and T-LESS) with full-cycle validation in simulation (CoppeliaSim), and tests three hypotheses

(accuracy, multimodal planning and temporal feasibility) using bootstrap confidence intervals. The results confirm accuracy competitive with the state of the art and an improvement over the GDR-Net++ baseline, as well as an end-to-end cycle below the industrial threshold of 10 s per instance; diffusion-based planning is functional, although its sampling time does not reach the stricter threshold set. As a contribution of this submission, a natural-language layer selects the target part from everyday instructions, with 100 % selection accuracy on a controlled benchmark. We conclude that the integration is feasible and reproducible on accessible hardware, and that the contribution lies in the mathematical integration, the methodological rigor and the reproducibility, rather than in a new architecture.

Keywords: 6-DoF pose estimation, bin picking, FoundationPose, Diffusion Policy, Transformers, BOP Challenge.

Índice de contenidos

1.	Introducción.....	1
1.1.	Justificación.....	1
1.2.	Planteamiento del problema.....	2
1.3.	Hipótesis.....	3
1.4.	Contribución del trabajo.....	4
1.5.	Estructura del trabajo.....	4
2.	Contexto y estado del arte.....	6
2.1.	Surveys y revisiones generales.....	6
2.2.	Métodos de estimación de pose 6-DoF.....	7
2.2.1.	Métodos clásicos y baselines.....	7
2.2.2.	Arquitecturas basadas en Transformers.....	8
2.3.	Datasets y benchmarks.....	9

2.4.	Nubes de puntos y fusión 3D.....	10
2.5.	Datos sintéticos, sim-to-real y políticas generativas.....	11
2.6.	Visual servoing y control robótico.....	12
2.7.	Conclusiones del estado del arte y brecha de investigación.....	12
2.8.	Síntesis comparativa y posicionamiento.....	15
2.8.1.	Preguntas abiertas: análisis crítico comparativo.....	16
3.	Objetivos concretos y metodología de trabajo.....	17
3.1.	Objetivo general.....	17
3.2.	Objetivos específicos.....	18
3.3.	Diseño experimental.....	19
3.3.1.	Resumen del diseño experimental.....	19
3.3.2.	Variables del experimento.....	20
3.3.3.	Hipótesis estadísticas y comparación con el baseline.....	21
3.3.4.	Protocolo de evaluación: particiones, ejecuciones y validación cruzada.....	23
3.3.5.	Justificación de las métricas seleccionadas.....	23
3.3.6.	Estudios de <i>ablation</i>	23
3.3.7.	Amenazas a la validez y mitigaciones.....	24
3.4.	Metodología del trabajo.....	24
3.4.1.	Entorno de desarrollo.....	24
3.4.2.	Planificación temporal.....	25
3.4.3.	Datasets y métricas de evaluación.....	25
3.4.4.	Licencias y reproducibilidad.....	25
3.5.	Tipo de TFM y reformulación.....	26
3.6.	Protocolo experimental ejecutado.....	26
3.7.	Análisis de robustez ante oclusión y ruido sensor.....	27

3.8.	Evidencia visual del pipeline en simulación.....	29
3.9.	Ablation: n_diffusion_steps.....	31
4.	Desarrollo específico de la contribución.....	32
4.1.	Tipo 2. Investigación con desarrollo práctico.....	32
4.1.1.	Componentes reutilizados y contribución propia.....	32
4.1.2.	Fundamentos matemáticos del pipeline.....	33
4.1.3.	Identificación de requisitos.....	35
4.1.4.	Descripción del sistema software o físico desarrollado.....	35
4.1.5.	Evaluación.....	35
4.1.6.	Arquitectura del pipeline integrado.....	36
4.1.7.	Algorithm 1: pseudocódigo del pipeline E2E.....	36
4.1.8.	Hiperparámetros del pipeline integrado.....	37
4.1.9.	Detalles de implementación.....	38
4.1.10.	Visual servoing PBVS: controlador en SE(3).....	39
4.1.11.	Diversidad multimodal de Diffusion Policy.....	40
4.1.12.	Visualización 3D de trayectorias.....	41
4.1.13.	Profiling del pipeline y cuello de botella.....	42
4.1.14.	Re-entrenamiento progresivo y escalabilidad del modelo Diffusion.....	43
4.1.15.	Decisiones de diseño y dificultades de implementación.....	44
4.1.16.	Selección de la pieza objetivo en entornos con distractores (clutter).....	47
4.1.17.	Análisis de casos fallidos y límites observados.....	49
4.1.18.	Bin picking guiado por lenguaje natural: arquitectura.....	50
4.1.19.	Ejecución extremo a extremo en simulación.....	50
4.1.20.	Resultados y validación de la capa de lenguaje.....	50
4.1.21.	Limitaciones y trabajo futuro de la capa de lenguaje.....	52

4.1.22.	Generación de objetos de prueba mediante text-to-CAD.....	53
4.1.23.	Resumen consolidado de la evidencia experimental.....	54
5.	Conclusiones y trabajo futuro.....	57
5.1.	Conclusiones.....	57
5.2.	Discusión y cierre de hipótesis.....	58
5.3.	Trabajo futuro.....	61
5.4.	Aporte e innovación del Trabajo Fin de Máster.....	63
5.4.1.	Aporte 1: Integración matemática unificada de dos paradigmas.....	63
5.4.2.	Aporte 2: Reproducibilidad cuantitativa del estado del arte sin GPU dedicada 63	
5.4.3.	Aporte 3: Rigor metodológico superior al estándar del área.....	63
5.4.4.	Aporte 4: Validación end-to-end con evidencia visual reproducible.....	64
5.5.	Comparativa de costes de hardware y democratización.....	64
5.6.	Alcance y limitaciones del trabajo.....	65
5.7.	Delimitación del alcance.....	66
	Referencias bibliográficas.....	67
Anexo A.	Repositorio de código y reproducibilidad.....	72

Índice de figuras

Figura 1. Flujo experimental del pipeline: Datos → FoundationPose → Pose 6-DoF → Diffusion Policy → Simulación → Métricas → Análisis estadístico. Las cuatro fases (percepción, planificación, ejecución y evaluación) se distinguen por color. Fuente: elaboración propia..	19
Figura 2. Curva de degradación AUC ADD-S frente al nivel de oclusión simulada (0–70 %) con IC 95 % por bootstrap (B = 200, n = 300 por dataset).....	27
Figura 3. Curva de degradación AUC ADD-S frente al ruido sintético en traslación (sigma 0–10 mm) con IC 95 % por bootstrap.....	27
Figura 4. Evidencia visual del pipeline ejecutado en CoppeliaSim Edu V4.10: (a) estimación de pose 6-DoF con FoundationPose, (b) trayectoria de agarre generada por Diffusion Policy, (c) ciclo end-to-end con panel de telemetría de latencias, y (d) escenario de robustez de bin picking. Fuente: elaboración propia a partir de las simulaciones del repositorio.....	29
Figura 5. Tres frames del pipeline E2E ejecutado en CoppeliaSim Edu V4.10 (vista cenital del bin picking + panel de telemetría con latencias en tiempo real, fase actual y aceptación de H3). Cada columna corresponde a un ciclo distinto sobre objetos YCB-V {obj_id=1, 6, 14}.....	30
Figura 6. Diagrama de arquitectura del pipeline TFM con marco matemático unificado $SE(3)/SO(3) + SDEs$	36
Figura 7. Convergencia del controlador PBVS sobre 50 poses reales de FoundationPose: curvas de error lineal (escala log) e histograma de tiempos de convergencia.....	39
Figura 8. Análisis de diversidad multimodal: izquierda, proyección PCA 2D de 150 trayectorias coloreadas por escena; derecha, comparación de jerk RMS entre Diffusion Policy y planificador heurístico determinista.....	40
Figura 9. Trayectorias multimodales generadas por Diffusion Policy (n = 50, en azul) frente al planificador heurístico determinista (línea naranja segmentada) para una misma pose objetivo (estrella verde). Tres vistas: perspectiva 3D, superior y lateral.....	41
Figura 10. Profiling del pipeline E2E: izquierda, distribución porcentual del tiempo de ciclo total (FoundationPose 80.2 %, CoppeliaSim 17.5 %, Diffusion DDIM-25 2.3 %); derecha,	

latencia de Diffusion Policy en función del número de pasos DDIM con barras mean / p95 sobre n = 15 muestras.....	42
Figura 11. Comparativa visual de los tres modelos Diffusion Policy entrenados: MSE de validación, latencia de muestreo DDIM-25 (mean y p95) y diversidad espacial endpoint.....	43
Figura 12. Progresión de la planificación de agarre del Iter 5 (aprendizaje supervisado) al Iter 7c. El ajuste fino por refuerzo (DPPO, Iter 6d) degrada la plausibilidad de agarre por olvido catastrófico; el currículo en dos fases (Iter 7a) recupera el depósito hasta el 92 %; la selección best-of-N (Iter 7b) y la corrección de la semilla del solver de IK (Iter 7c) restauran agarre e IK, elevando el éxito end-to-end de pick-and-place al 84 %, por encima del baseline supervisado (60 %). n = 50, seed 2026.....	47
Figura 13. Agarre en entornos con distractores (clutter; n = 25, 2 distractores, semilla 2026). (a) La selección explícita de la pieza objetivo (v9) eleva la tasa de agarre correcto al 96–100 % frente al 84–88 % sin selección (v8). (b) La estrategia verify-then-act reduce el desplazamiento máximo de los distractores de ~185 cm (media) a 4.9 cm (mediana). Fuente: elaboración propia a partir de eval_v9_clutter.json.....	48
Figura 14. Ejecución extremo a extremo de la instrucción «dame el cubo rojo de la izquierda» en una escena con variedad de formas. Fuente: elaboración propia.....	52
Figura 15. Catálogo de piezas generadas desde descripciones en lenguaje mediante build123d: escuadra en L, tuerca hexagonal y bloque escalonado. Fuente: elaboración propia.....	54

Índice de tablas

Tabla 1. <i>Organización del trabajo en grupo</i>	XI
Tabla 2. Síntesis comparativa de métodos relevantes para estimación de pose 6-DoF y planificación de agarre.....	15
Tabla 3. Resumen consolidado del diseño experimental. Fuente: elaboración propia.....	19
Tabla 4. Variables del diseño experimental. Fuente: elaboración propia.....	20
Tabla 5. Ablation de n_diffusion_steps en Diffusion Policy (M1 Pro / MPS, n = 30).....	31
Tabla 6. Hiperparámetros del pipeline integrado FoundationPose + Diffusion Policy + Coppeliasim.....	37
Tabla 7. Comparativa de modelos Diffusion Policy con configuración progresiva de datos, épocas y capacidad. Bootstrap CI 95 % sobre 50 muestras de trayectoria por modelo. Métricas: MSE de validación, latencia DDIM-25 sobre MPS, jerk RMS de la trayectoria muestreada y diversidad endpoint (dispersión espacial).....	43
Tabla 8. Resultados del experimento de agarre en clutter por condición (n = 25, 2 distractores, semilla 2026). Fuente: elaboración propia.....	48
Tabla 9. Comparación de capacidades entre la Entrega 3 y la Entrega 4. Fuente: elaboración propia.....	51
Tabla 10. Evidencia de validación de la capa de lenguaje (junio de 2026). Fuente: elaboración propia.....	51
Tabla 11. Estimación de pose 6-DoF y viabilidad de agarre de tres piezas generadas mediante text-to-CAD, a partir de profundidad real en simulación. Fuente: elaboración propia.....	54
Tabla 12. Resumen consolidado de los diez experimentos del TFM con hallazgos cuantitativos y trazabilidad al repositorio.....	54
Tabla 13. Trazabilidad de los experimentos a objetivos e hipótesis. Fuente: elaboración propia.	55
Tabla 14. Cierre de las hipótesis de investigación: criterio de aceptación, evidencia y decisión. Fuente: elaboración propia.....	58

Tabla 15. Comparativa de costes de hardware para reproducir el estado del arte en pose
estimation 6-DoF + planificación.....64

Organización del trabajo en grupo

A continuación se detalla cómo se repartió el trabajo entre los dos integrantes del grupo, qué objetivos se asignaron y qué mecanismos de coordinación se emplearon durante el desarrollo del TFM.

Partes que aborda el TFE

Cada estudiante asumió módulos técnicos diferenciados de alta complejidad, integrados en una contribución común:

1. Implementación del pipeline de estimación de pose 6-DoF con FoundationPose (*Transformers*) y evaluación en benchmarks BOP (T-LESS, YCB-Video).
2. Implementación de Diffusion Policy para generación de trayectorias de agarre multimodales y configuración del entorno de simulación CoppeliaSim + ROS 2.
3. Formalización matemática: representaciones en $SE(3)/SO(3)$, mecanismos de atención *Transformer*, SDEs y score matching para modelos de difusión.
4. Integración del pipeline completo: percepción + planificación + ejecución robótica con visual servoing.
5. Evaluación experimental y análisis comparativo con métodos clásicos en métricas BOP estándar.

Distribución y estructura de la memoria

Tabla 1. Organización del trabajo en grupo.

Organización del trabajo en grupo - Desarrollo de la memoria	
Apartado de la memoria	Responsables
Introducción	Giocrisrai y José Miguel
Contexto y estado del arte	Giocrisrai y José Miguel

Objetivos y metodología de trabajo	Giocrisrai y José Miguel
Implementación del pipeline de estimación de pose 6-DoF con FoundationPose (<i>Transformers</i>) y evaluación en benchmarks BOP (T-LESS, YCB-Video).	Giocrisrai
Implementación de Diffusion Policy y configuración CoppeliaSim + ROS 2	José Miguel
Formalización matemática: $SE(3)/SO(3)$, <i>Transformers</i>, SDEs, score matching	Giocrisrai
Integración del pipeline completo: percepción + planificación + ejecución	Giocrisrai y José Miguel
Evaluación experimental y análisis comparativo en métricas BOP	Giocrisrai y José Miguel
Conclusiones	Giocrisrai y José Miguel

Fuente: Elaboración propia.

Objetivo del TFE desde el punto de vista de la adquisición de conocimientos

En cuanto a los conocimientos puestos en juego, el TFM cruza varias disciplinas del máster. Del álgebra toma los grupos de Lie $SO(3)/SE(3)$ y los cuaterniones. Del análisis hereda las ecuaciones diferenciales estocásticas y los procesos de Markov; de la estadística, el score matching y la estimación de densidades; de la computación, el deep learning y las arquitecturas Transformer junto a los modelos de difusión; y de la ingeniería, la robótica, la visión por computador y el control. Cada estudiante desarrolló módulos técnicos diferenciados de alta complejidad, y su integración es la que da al conjunto un carácter holístico de interés académico e industrial.

Mecanismos de coordinación empleados

Para coordinarnos se recurrió a reuniones semanales por videoconferencia, a un repositorio compartido en GitHub para el código y la documentación (Godoy Bonillo & Carrasco, 2026), y a Google Drive para los archivos del documento. La comunicación diaria iba por WhatsApp/Telegram. El código se revisó de forma mutua (code review). Los cuadernos de entrenamiento se compartieron en Google Colab, y CoppeliaSim se mantuvo con configuraciones sincronizadas para que los experimentos fueran reproducibles entre ambos.

1. INTRODUCCIÓN

Este Trabajo Fin de Máster se ocupa de uno de los retos más vigentes de la robótica industrial: la estimación de pose 6-DoF (seis grados de libertad) para bin picking robótico. Lo aborda integrando dos de las arquitecturas más recientes del deep learning. El bin picking (la recogida automática de piezas amontonadas sin orden en contenedores) sigue siendo un problema abierto. Resolverlo con eficiencia repercutiría de lleno en la productividad de líneas automatizadas de automoción, electrónica y logística.

Estimar la pose 6-DoF consiste en recuperar la posición (traslación en $\mathbb{R}^3$) y la orientación (rotación en $SO(3)$) de un objeto, lo que se formaliza como un elemento del grupo especial euclídeo $SE(3)$. En la industria el problema se complica. Hay oclusiones entre piezas apiladas, cambios de iluminación, superficies metálicas que reflejan y ausencia de textura. Ante este panorama, los métodos clásicos de template matching y descriptores geométricos se quedan cortos (Thalhammer et al., 2024).

La propuesta es un pipeline completo que articula dos modelos. FoundationPose (Wen et al., 2024), basado en Transformers y distinguido en el BOP Challenge 2024, estima la pose por atención cruzada 2D-3D. Diffusion Policy (Chi et al., 2023) plantea la planificación de trayectorias de agarre como un proceso de difusión inversa que se resuelve con ecuaciones diferenciales estocásticas. Unir ambos paradigmas bajo un análisis matemático cuidado: esa es la contribución original de este Trabajo Final de Maestría.

1.1.JUSTIFICACIÓN

Automatizar el bin picking con visión artificial y deep learning es una necesidad clara de la Industria 4.0. La revisión sistemática de Cordeiro et al. (2026), publicada en Robotics and Autonomous Systems, coloca el bin picking entre los problemas a medio resolver de la robótica industrial. Las tasas de éxito varían de forma notable según las propiedades del objeto (textura, simetría, material) y el grado de oclusión dentro del contenedor.

Liu et al. (2025a) ordenan los métodos clásicos de estimación de pose en tres familias: los basados en correspondencias (PnP, ICP), los de regresión directa (PoseCNN, GDR-Net) y los de render-and-compare (MegaPose), que comparten las mismas debilidades: requieren datos de

entrenamiento por objeto, generalizan mal a piezas nuevas y dejan fuera la naturaleza multimodal del agarre.

La arquitectura Transformer surgió en el procesamiento de lenguaje natural (Vaswani et al., 2017). Su atención multi-cabeza pronto transformó también la visión por computador, ya que modela dependencias de largo alcance entre regiones de una imagen o entre las modalidades 2D y 3D. FoundationPose (Wen et al., 2024) aprovecha esa capacidad: empareja los renders del modelo CAD con observaciones RGB-D reales y alcanza resultados de vanguardia sin reentrenar para cada objeto.

Los modelos de difusión ofrecen una formulación elegante para planificar trayectorias. Diffusion Policy (Chi et al., 2023) representa la distribución de trayectorias de agarre como un proceso de difusión condicionado por la observación visual, que se resuelve con score matching y dinámica de Langevin. El planteamiento capta sin esfuerzo la multimodalidad del bin picking. Para un mismo objeto coexisten varias formas de agarre igual de válidas.

El interés académico del trabajo se apoya en tres aspectos. El primero, la integración de los dos paradigmas, Transformers y difusión, en un pipeline unificado de bin picking que la literatura aún no había abordado. El segundo es el análisis matemático de los mecanismos implicados (grupos de Lie $SE(3)/SO(3)$, representaciones de rotación, procesos estocásticos y convergencia del score matching); su tratamiento formal se reserva al capítulo de desarrollo, de modo que la introducción no pierda concisión, y ese rigor encaja con el nivel de un Máster en Ingeniería Matemática y Computación. El tercero es la validación sobre benchmarks reconocidos (BOP Challenge), que abre la puerta a una comparación directa y reproducible con el estado del arte.

1.2. PLANTEAMIENTO DEL PROBLEMA

El problema central de este Trabajo de fin de maestría consiste en estimar de forma robusta la pose 6-DoF de objetos industriales parcialmente ocluidos en escenarios de bin picking. Formalmente, dada una imagen RGB-D de una cámara calibrada con matriz de intrínsecos K y un modelo 3D del objeto (*mesh* CAD o nube de puntos), se busca la transformación rígida $T \in SE(3)$ que alinea el sistema de coordenadas del objeto con el de la cámara.

Esa transformación se descompone en una rotación $R \in SO(3)$ y una traslación $t \in \mathbb{R}^3$. La rotación admite distintas parametrizaciones (cuaterniones, ángulos de Euler o la

representación continua de 6 dimensiones de Zhou et al., 2019), cuya elección no es un detalle menor, pues condiciona la convergencia y la estabilidad del entrenamiento. Su tratamiento formal, junto con la formulación de $SE(3)$ como grupo de Lie sobre el marco sistematizado por Solà et al. (2018), se desarrolla en el Capítulo 4.

El problema exige también planificar la trayectoria de agarre. A partir de la pose 6-DoF estimada se debe generar una trayectoria articular que permita al manipulador alcanzar la pieza, sujetarla y extraerla del contenedor sin colisiones. La multimodalidad reaparece en esta fase, ya que para una misma escena distintas trayectorias resultan igualmente válidas.

El problema impone cinco restricciones: (a) precisión submilimétrica para el ensamblaje industrial; (b) robustez ante oclusiones parciales, hasta del 70% del objeto; (c) generalización a piezas sin textura, como las del dataset T-LESS; (d) compatibilidad con el tiempo de ciclo industrial, con inferencia por debajo de 500 ms; y (e) viabilidad sin GPU dedicada de alto coste.

1.3.HIPÓTESIS

Del problema y del estado del arte surgen tres hipótesis verificables que orientan el diseño experimental:

H1 (Precisión de pose). Un pipeline basado en FoundationPose mejora el *Mean AR* (la métrica oficial del BOP Challenge) en al menos 3 puntos porcentuales respecto al baseline GDR-Net++ en T-LESS y YCB-Video, y mantiene un *recall* a 10 mm sobre ADD-S por encima del 95 % en ambos datasets. La aceptación se decide con un intervalo de confianza al 95 % por bootstrap no paramétrico ($B = 1000$ resamples) sobre las instancias evaluadas.

H2 (Planificación multimodal). Diffusion Policy genera trayectorias de agarre con un score medio de al menos 0.95 y un tiempo de muestreo por debajo de 50 ms por trayectoria, y recoge la multimodalidad propia del agarre que los planificadores deterministas no llegan a representar.

H3 (Viabilidad sin GPU dedicada). El pipeline completo (percepción, planificación y ejecución en simulación) corre sobre una arquitectura híbrida, local (Apple M1 Pro) y remota (Google Colab Tesla T4), con un tiempo de ciclo compatible con bucles industriales, por debajo de 10 s por instancia.

Cada hipótesis se contrasta cuantitativamente en los capítulos de desarrollo y conclusiones. Se emplean métricas BOP estándar, intervalos de confianza al 95 % por bootstrap y comparación directa con el *leaderboard* oficial.

1.4.CONTRIBUCIÓN DEL TRABAJO

Las contribuciones de este Trabajo Fin de Máster se organizan en cinco ejes, que el Capítulo 5 desarrolla y cierra con la evidencia experimental.

En el plano metodológico, se formula un pipeline unificado que integra FoundationPose (percepción basada en Transformers) y Diffusion Policy (planificación por difusión) bajo un mismo marco geométrico y estocástico. En el plano matemático, se explicita la conexión entre la atención cruzada 2D-3D, la geometría de los grupos de Lie $SE(3)/SO(3)$ y el muestreo de Langevin condicionado. En el empírico, el sistema se evalúa sobre los benchmarks BOP (T-LESS e YCB-Video) y se valida el ciclo completo en simulación con intervalos de confianza por bootstrap. En reproducibilidad, se libera un repositorio público con los hiperparámetros, las semillas y los entornos Docker necesarios para replicar el pipeline sin hardware industrial costoso. Por último, en el plano de la transferencia, se demuestra la viabilidad del bin picking con deep learning sobre hardware accesible, al alcance de pequeñas y medianas empresas. Esta entrega añade, además, una capa de comprensión de lenguaje natural que permite indicar la pieza objetivo mediante instrucciones cotidianas, integrada de forma poco invasiva sobre el pipeline.

1.5.ESTRUCTURA DEL TRABAJO

La memoria se organiza en cinco capítulos. El Capítulo 1, el presente, plantea el problema, lo justifica y lo formaliza. El Capítulo 2 revisa el contexto y el estado del arte a partir de una treintena de publicaciones agrupadas en seis categorías temáticas, y cierra señalando la brecha de investigación que da pie a este trabajo.

El Capítulo 3 fija los objetivos (general y específicos) y la metodología, junto con el diseño experimental, la estrategia híbrida local-remota y el protocolo estadístico. El Capítulo 4 desarrolla la contribución: la arquitectura del pipeline integrado, su fundamento en los grupos de Lie $SE(3)/SO(3)$ y en las ecuaciones diferenciales estocásticas de los modelos de difusión, los detalles de implementación y la evidencia experimental con métricas BOP. El Capítulo 5 cierra con las conclusiones, el cierre de hipótesis y las líneas de trabajo futuro.

2. CONTEXTO Y ESTADO DEL ARTE

Este capítulo revisa el estado del arte en estimación de pose 6-DoF y bin picking robótico. La base es un catálogo de más de treinta publicaciones científicas, todas validadas con DOI o referencia arXiv, repartidas en seis categorías temáticas. Su finalidad es situar este trabajo final de maestría en el panorama actual de investigación, reconocer las técnicas más relevantes y justificar las decisiones de diseño del pipeline propuesto. La exposición va de lo general a lo específico. Arranca con los surveys y sigue con los métodos, los datasets y las técnicas complementarias. Cierra con la brecha de investigación.

2.1. SURVEYS Y REVISIONES GENERALES

La revisión abre con el survey de Liu et al. (2025a) en el International Journal of Computer Vision (IJCV). Allí se sistematizan más de 200 métodos de estimación de pose con deep learning a lo largo de cuatro ejes: el tipo de entrada (RGB, RGB-D o nubes de puntos), la representación de la pose (cuaterniones, matrices de rotación o representación 6D continua), la estrategia de estimación (regresión directa, correspondencias, render-and-compare o voting) y el paradigma de entrenamiento (supervisado, auto-supervisado o *few-shot*). Su conclusión es clara: hay un desplazamiento hacia arquitecturas *Transformer* y hacia métodos que generalizan a objetos no vistos. Esa tendencia respalda la elección de FoundationPose como método central de este trabajo.

Guan et al. (2024) suman a esa visión un survey en Sensors. Aquí los métodos 6-DoF se ordenan por escenario de aplicación: realidad virtual/aumentada, conducción autónoma y robótica. La taxonomía ayuda a precisar los requisitos del dominio industrial abordado aquí: precisión submilimétrica, robustez ante oclusiones y compatibilidad con el tiempo de ciclo. Los autores constatan que el deep learning supera de forma consistente a los enfoques clásicos en los tres escenarios. La brecha crece en robótica. La variabilidad de condiciones operativas es ahí mucho más acusada.

Ya en el bin picking, Cordeiro et al. (2026) firman en Robotics and Autonomous Systems una revisión de la percepción visual para esta tarea que recorre la literatura desde 2009. El trabajo traza el paso de los descriptores geométricos a las arquitecturas de deep learning y separa tres subproblemas: localización del objeto, estimación de pose y predicción de agarre. Su

conclusión es contundente. Integrar esos tres subproblemas en un pipeline end-to-end sigue siendo un reto abierto, justamente el que aborda este trabajo.

Kleeberger et al. (2020), en *Current Robotics Reports*, examinan el *grasping* robótico por aprendizaje y el compromiso entre métodos model-free (más generalizables pero menos precisos) y model-based (más precisos pero menos adaptables). Esa dualidad encaja con el diseño propuesto: FoundationPose opera como bloque model-based (requiere CAD) y Diffusion Policy como componente model-free de planificación. Thalhammer et al. (2024), en *IEEE Transactions on Robotics*, enumeran a su vez los retos de la estimación de pose 6D monocular: la ambigüedad por simetría, la degradación por oclusión y las limitaciones de las representaciones de rotación. Son tres cuestiones que se tratan formalmente en los Capítulos 4 y 5 de este trabajo.

2.2. MÉTODOS DE ESTIMACIÓN DE POSE 6-DOF

Los métodos de estimación de pose 6-DoF han evolucionado mucho en la última década. El recorrido va de los enfoques basados en CNN a las arquitecturas *Transformer*. A continuación se presentan los métodos más relevantes, ordenados desde los enfoques clásicos hasta las propuestas más recientes.

2.2.1. Métodos clásicos y baselines

Entre los trabajos seminales de estimación de pose 6-DoF con deep learning destaca PoseCNN (Xiang et al., 2018), presentado en *Robotics: Science and Systems*. Su arquitectura convolucional aborda la pose en dos frentes: localiza el centro del objeto mediante votación por píxeles y regresa la orientación directamente como cuaternión. Junto al método, los autores liberaron el dataset YCB-Video (21 objetos, 133K frames), hoy uno de los benchmarks de referencia. Enfoques posteriores ya superaron su precisión. Aun así, PoseCNN fijó el paradigma end-to-end que ha vertebrado el área durante la última media década.

GDR-Net (Wang et al., 2021), presentado en CVPR, refina el paradigma anterior con una regresión guiada por geometría. En vez de predecir la pose directamente, infiere primero una representación intermedia (coordenadas NOCS y mapas de correspondencia densos) y resuelve la pose con un módulo PnP diferenciable. Adopta además la representación de rotación 6D continua de Zhou et al. (2019), que evita las discontinuidades de cuaterniones y matrices de rotación. Su evolución, GDR-Net++, encabezó el BOP Challenge 2022

(Sundermeyer et al., 2024). Quedó claro el beneficio de la representación geométrica intermedia. En este trabajo actúa como baseline de referencia y permite cuantificar la ganancia de las arquitecturas *Transformer* frente a la regresión directa.

MegaPose (Labbé et al., 2022), en la Conference on Robot Learning (CoRL), adopta un esquema render-and-compare entrenado sobre millones de escenas sintéticas. Renderiza el modelo CAD en múltiples poses candidatas, las contrasta con la observación real mediante un codificador CNN y retiene la de mayor similitud. Al demostrar que el entrenamiento sintético masivo habilita la generalización a objetos no vistos, anticipa el paradigma de modelos fundacionales que FoundationPose consolidaría. Estas debilidades comunes (reentrenamiento por objeto y escasa generalización a piezas nuevas) justifican adoptar un modelo fundacional como FoundationPose en la fase de percepción.

2.2.2. Arquitecturas basadas en Transformers

FoundationPose (Wen et al., 2024), desarrollado por NVIDIA y distinguido como Highlight Paper en CVPR 2024, marca el estado del arte vigente en estimación de pose 6-DoF. Ofrece un framework unificado de estimación y *tracking* de pose para objetos nuevos (novel objects) sin reentrenamiento. Su núcleo es la atención cruzada (cross-attention) entre los renders 2D del modelo CAD y las observaciones 3D de la cámara RGB-D. Opera directamente sobre el grupo $SE(3)$. Un refinamiento iterativo por ICP neuronal aproxima progresivamente la pose correcta.

La contribución principal de FoundationPose está en su capacidad de generalización. Una vez entrenado, estima la pose de cualquier objeto a partir de su modelo CAD o de una pequeña colección de imágenes de referencia, y lo hace sin reentrenamiento adicional. Referente del estado del arte de código abierto y distinguida en el BOP Challenge 2024, FoundationPose rinde de forma competitiva en múltiples datasets (T-LESS, YCB-Vídeo, LM-O, TUD-L, IC-BIN, ITODD, HB). Esa generalización sin reentrenamiento la hace idónea para entornos industriales de bin picking, donde las piezas cambian a menudo y reentrenar para cada nueva pieza sale prohibitivo en tiempo y coste.

GenFlow (Moon et al., 2024), también en CVPR 2024, plantea un refinamiento iterativo guiado por flujo óptico. Estima un campo de flujo denso entre el renderizado de la pose actual y la observación real, y lo usa para corregir la pose de forma sucesiva. El método lideró los benchmarks de objetos no vistos tanto en RGB como en RGB-D, lo que confirma el flujo óptico

como señal supervisora eficaz para el refinamiento. CMT-6D (Liu, S. et al., 2024), en cambio, recurre a *Transformers* ligeros para la fusión *cross-modal* y gana eficiencia computacional a cambio de una ligera pérdida de precisión. Junto con FoundationPose, estos enfoques encarnan la tendencia hacia modelos fundacionales que generalizan a objetos arbitrarios sin reentrenamiento. Es precisamente esa generalización zero-shot la que motiva elegir FoundationPose como bloque de percepción del pipeline propuesto.

2.3.DATASETS Y BENCHMARKS

La comparación rigurosa exige benchmarks estandarizados. El BOP Challenge (Hodañ et al., 2025; Sundermeyer et al., 2024) cumple ese papel y opera como referencia de facto de la comunidad. Define las métricas VSD (Visible Surface Discrepancy), MSSD (Maximum Symmetry-Aware Surface Distance) y MSPD (Maximum Symmetry-Aware Projection Distance), que tratan correctamente los objetos simétricos, tan habituales en la industria, allí donde métricas clásicas como ADD fallan. Su edición 2024 sumó tareas model-free y datasets con sensores AR/VR (BOP-H3) y logró una mejora del 22% en precisión media respecto a 2023.

La rápida evolución del campo se nota en las ediciones más recientes del benchmark. En el BOP Challenge 2024, FreeZeV2.1 (Caraffa et al., 2025), un método sin entrenamiento que fusiona modelos fundacionales geométricos y visuales congelados, alcanzó el mejor resultado en localización 6D de objetos no vistos: un 22 % más de precisión en BOP-Classic-Core que el mejor método de 2023, eso sí, a un coste de inferencia elevado (24.9 s por imagen). La edición 2025 incorporó además la categoría BOP-Industrial, con datasets como XYZ-IBD (Huang et al., 2025) orientados específicamente al bin picking de piezas industriales sin textura, con escenas atestadas y captura multi-vista. Se configura así un banco de pruebas alineado con el caso de uso de este trabajo.

T-LESS (Hodañ et al., 2017) es el dataset de referencia para piezas industriales sin textura. Reúne 30 objetos con unas 39K imágenes de entrenamiento y 10K de test, adquiridas con tres sensores sincronizados (Primesense, Kinect v2 y cámara estéreo). Reproduce los desafíos del bin picking real: superficies homogéneas sin textura, simetrías rotacionales y discretas, y oclusiones severas entre piezas apiladas. Es uno de los dos datasets principales de evaluación de este trabajo.

YCB-Video (Xiang et al., 2018) aporta 21 objetos domésticos con textura variada en 133K *frames* de vídeo. Sirve como benchmark complementario para medir la generalización ante características visuales diversas. Frente a T-LESS, sus objetos lucen colores y texturas distintivos que facilitan la segmentación, aunque añaden reflejos especulares y transparencias. Combinar ambos permite evaluar a la vez la robustez sin textura (T-LESS) y la discriminación visual (YCB-Video).

GraspNet-1Billion (Fang et al., 2020) complementa estos datasets de pose con más de 1.1 mil millones de poses de agarre anotadas en 88 objetos y 190 escenas. Aporta así datos de entrenamiento para el componente de planificación de agarre del pipeline. En el bin picking industrial, dos datasets recientes amplían los benchmarks clásicos. XYZ-IBD (Huang et al., 2025) aporta 15 piezas industriales en 75 escenas y 22K imágenes, con anotaciones de pose de precisión milimétrica capturadas en condiciones reales de fábrica. IndustryShapes (2026) introduce componentes de ensamblaje industrial con superficies reflectantes y simetrías complejas. Por su ausencia de textura, sus simetrías y sus oclusiones severas, T-LESS e YCB-Video resultan los benchmarks idóneos para validar el pipeline, y se adoptan como referencia experimental de este trabajo.

2.4. NUBES DE PUNTOS Y FUSIÓN 3D

El procesamiento de nubes de puntos pesa mucho en la estimación de pose 6-DoF, pues los sensores RGB-D aportan geometría 3D que complementa la imagen RGB. PointNet (Qi et al., 2017a), en CVPR, fue la primera red capaz de operar directamente sobre nubes de puntos respetando la invariancia a permutación mediante pooling simétrico. Su extensión PointNet++ (Qi et al., 2017b), en NeurIPS, añade aprendizaje jerárquico de features locales sobre particiones anidadas del espacio y captura con mayor finura las estructuras geométricas.

DenseFusion (Wang et al., 2019), presentado en CVPR, integra color y profundidad a nivel de píxel mediante embeddings densos, con un refinamiento iterativo de pose posterior. Los autores demuestran algo concreto: fusionar densamente los features 2D y 3D punto a punto supera a la fusión tardía (*late fusion*) a nivel de objeto. De ahí bebe el módulo de ICP neuronal de FoundationPose.

Liu et al. (2025b) firman en ACM Computing Surveys una revisión del deep learning sobre nubes de puntos en escenarios industriales. Cubre la estimación de pose, la inspección de

defectos y la medición dimensional. ES6D (Mo et al., 2022) aborda la simetría en CVPR y define la métrica A/M-GPD (Ambiguity/Multi-path Geodesic Pose Distance) para resolver la ambigüedad de los objetos simétricos, una capacidad pertinente porque las piezas de T-LESS abundan en simetrías rotacionales que las métricas convencionales no manejan bien. Estas técnicas de fusión densa color-profundidad y de tratamiento de la simetría sustentan el refinamiento por ICP neuronal que incorpora FoundationPose.

2.5.DATOS SINTÉTICOS, SIM-TO-REAL Y POLÍTICAS GENERATIVAS

Para entrenar estimadores de pose, la síntesis de datos resulta decisiva: sortea la escasez y el coste de las anotaciones manuales. Konstantinou et al. (2024) validan el uso de GANs y rendering avanzado para ensamblaje industrial y lo comprueban con un robot real en picking de componentes electrónicos. ParaPose (Hagelskjær y Buch, 2022), en IROS, optimiza automáticamente los parámetros de domain randomization y alcanza un 82% de recall en el dataset OCCLUSION usando solo datos sintéticos. NVIDIA Isaac Sim Replicator (NVIDIA, 2024) ofrece un pipeline industrial completo de generación sintética con domain randomization automática, compatible con FoundationPose y desplegable en producción.

El dataset CEPB (Tripicchio et al., 2024), publicado en Frontiers in Robotics and AI, aporta cerca de 1.5 millones de imágenes fotorrealistas derivadas de 50K escenas cluttered. Los objetos vienen anotados en pose y segmentación: rígidos, blandos y deformables. Sus resultados sugieren que el renderizado fotorrealista entrena modelos que transfieren al mundo real con un gap mínimo.

Diffusion Policy (Chi et al., 2023), publicado en Robotics: Science and Systems, marca una referencia dentro de las políticas generativas para robótica. Chi et al. plantean el aprendizaje de políticas visuomotoras como un proceso de difusión condicional y extienden al dominio robótico los modelos de difusión probabilísticos (Ho et al., 2020). Apoyándose en la formulación unificada de ecuaciones diferenciales estocásticas (SDEs) de Song et al. (2021), generan las trayectorias de acción mediante SDEs en reversa: parten de ruido gaussiano y el denoising aplica score matching para recuperar la distribución objetivo, mientras la dinámica de Langevin habilita el muestreo de distribuciones multimodales, es decir, múltiples agarres válidos para una misma escena. Los autores reportan una mejora del 46.9% sobre el estado del arte previo en 12 tareas de manipulación y superan a las políticas deterministas y a los

métodos basados en GMM o VAE en el modelado de acciones multimodales. Esta superioridad en el modelado multimodal es la que justifica emplear Diffusion Policy como planificador de agarre frente a un planificador determinista.

2.6. VISUAL SERVOING Y CONTROL ROBÓTICO

La ejecución del agarre exige un control visual (visual servoing) que corrija las desviaciones durante la aproximación. Li et al. (2025), en *Complex & Intelligent Systems*, proponen un PBVS reforzado con aprendizaje por refuerzo profundo y *Transformers*. Su esquema *actor-critic* con PPO para el control de aceleración mejora notablemente la precisión y la velocidad de convergencia frente a los controladores PID clásicos.

Ribeiro et al. (2021), en *Robotics and Autonomous Systems*, combinan una CNN de detección de agarre en tiempo real (entrenada en el *Cornell Dataset*) con control por visual servo y superan el 90% de precisión con un robot Kinova Gen3 en escenas cluttered. NVIDIA Isaac Manipulator (Murali et al., 2024) acredita la viabilidad industrial del pick-and-place con FoundationPose como percepción: unos 8 segundos por ciclo en un sistema real con piezas metálicas especulares. Un referente directo para el pipeline propuesto. Xue et al. (2025) llevan el visual servoing con *Transformers* a robots humanoides mediante un Distance Estimation *Transformer* que fusiona varias cámaras con los ángulos articulares; consiguen errores de 0.8-1.3 mm y tasas de éxito del 93-100% en alineación de micro-objetos. Estos resultados respaldan incorporar un control por visual servoing (PBVS) en la fase de ejecución; no obstante, su validación con un robot real excede el alcance de este trabajo, que se restringe a simulación y deja la transferencia sim-to-real como línea futura.

2.7. CONCLUSIONES DEL ESTADO DEL ARTE Y BRECHA DE INVESTIGACIÓN

Revisadas estas publicaciones, emergen cuatro tendencias que sustentan las decisiones de diseño del presente TFM. La primera: las arquitecturas *Transformer* se han convertido en el paradigma dominante para la estimación de pose 6-DoF y superan de forma consistente a los métodos de regresión directa y de correspondencias, gracias a su capacidad de modelar relaciones de largo alcance entre modalidades heterogéneas (2D y 3D). La segunda: los modelos de difusión ofrecen una formulación matemáticamente rigurosa para la planificación de trayectorias robóticas y capturan con naturalidad la multimodalidad inherente al problema de agarre. La tercera tiene que ver con los datos. Los datos sintéticos con domain

randomization han demostrado bastar para entrenar modelos de pose transferibles al mundo real, lo que elimina la dependencia de costosas anotaciones manuales. La cuarta: la integración de visual servoing con deep learning mejora la robustez del sistema ante perturbaciones y errores de estimación.

La brecha de investigación está en integrar ambos paradigmas, Transformers para percepción y modelos de difusión para planificación, dentro de un pipeline unificado y coherente para bin picking. FoundationPose resuelve el problema de percepción (su localización y orientación) y Diffusion Policy resuelve el de planificación (la estrategia de agarre), pero, en la literatura revisada (búsqueda en IEEE Xplore, ACM DL y Scopus, abril-mayo 2026), no se ha identificado un trabajo previo que explore su integración end-to-end junto al análisis matemático formal de los mecanismos involucrados: la geometría de $SE(3)/SO(3)$ que conecta percepción y acción, las SDEs que fundamentan la generación de trayectorias y el score matching que permite el aprendizaje no supervisado de distribuciones complejas. Ahí reside la contribución original de este trabajo final de maestría.

Formulación precisa del *gap científico*. La literatura indexada no recoge todavía (búsqueda en IEEE Xplore, ACM DL y Scopus, abril-mayo 2026) un pipeline que combine a la vez tres elementos: (i) un estimador de pose 6-DoF basado en *foundation Transformer* capaz de generalizar zero-shot a objetos no vistos a partir de su CAD; (ii) un planificador de agarre formulado como SDE inversa con score matching, capaz de muestrear múltiples modos de trayectoria; y (iii) un acoplamiento explícito $SE(3) \rightarrow action\ space$ derivado analíticamente sobre la variedad de Lie. El problema concreto que se resuelve es, entonces, cómo construir y validar empíricamente un sistema (i)+(ii)+(iii) que además sea reproducible sin GPU industrial dedicada y evaluable con el protocolo BOP estándar.

Posicionamiento del TFM frente al estado del arte. Frente a la familia FoundationPose / GenFlow / CMT-6D, este TFM no propone un nuevo estimador de pose ni reentrena el modelo. Lo adopta como bloque de percepción y aporta el acoplamiento matemático explícito con la fase de planificación. Frente a la familia Diffusion Policy / Ho et al. (2020) / Song et al. (2021), tampoco introduce una nueva SDE, pero adapta la formulación a un espacio de acción condicionado por la pose en $SE(3)$ y a un escenario industrial cluttered que el *paper* original no contemplaba. Frente al baseline GDR-Net++ (GDRNPP; Liu et al., 2025c), este TFM se posiciona como su sucesor directo a nivel empírico para bin picking: el contraste cuantitativo

entre ambos en BOP-T-LESS constituye la evidencia central de la hipótesis H1.1. La mejora aportada se ubica en la **integración vertical** (percepción $\leftrightarrow$ planificación) y en la **articulación teórica** (geometría $\leftrightarrow$ dinámica estocástica), no en una nueva arquitectura aislada.

2.8.SÍNTESIS COMPARATIVA Y POSICIONAMIENTO

A continuación se sintetizan los métodos más relevantes en una tabla comparativa, organizada por tipo de método, dataset principal de evaluación, métrica reportada y limitaciones identificadas. Sobre ella se apoya el análisis crítico que sigue.

Tabla 2. Síntesis comparativa de métodos relevantes para estimación de pose 6-DoF y planificación de agarre.

Método	Tipo	Dataset principal	Métrica reportada	Limitación
PoseCNN (Xiang, 2018)	CNN + cuaterniones	YCB-Video	ADD-S AUC 0.75	Discontinuidad rotacional; reentrenamiento por objeto
GDR-Net++ (GDRNPP; Liu et al., 2025c)	Regresión guiada por geometría + 6D continua	YCB-V / T-LESS	Mean AR 0.867 / 0.767	Dependencia de PnP; sin generalización a objetos no vistos
MegaPose (Labbé, 2022)	Render-and-compare CNN	BOP	Mean AR ≈ 0.74	Latencia alta por renderizado masivo
FoundationPose (Wen, 2024)	Transformer cross-attention + ICP neural	YCB-V / T-LESS	Mean AR 0.897 / 0.803	Licencia NC; requiere CAD del objeto
GenFlow (Moon, 2024)	Flujo óptico + refinamiento	BOP unseen	1.º BOP 2024 unseen	Acumulación de error en escenas largas
ES6D (Mo, 2022)	Simetría explícita	T-LESS	A/M-GPD	No generaliza a novel objects
Diffusion Policy (Chi, 2023)	SDE generativa para acción	RoboMimic	+46.9 % vs SOTA previo	Requiere demostraciones
Este TFM (FP + Diffusion)	Transformer + Diffusion integrados	YCB-V / T-LESS	AUC ADD-S 0.908 / 0.957; muestreo 118 ms (DDIM-25)	Validación sim-only en esta entrega

Fuente: Elaboración propia a partir de las publicaciones referenciadas y los resultados experimentales del presente TFM.

Análisis crítico. Los métodos de regresión directa (PoseCNN, GDR-Net++) presentan latencia baja, pero penalizan la generalización a objetos no vistos durante el entrenamiento; eso obliga a reentrenamientos costosos cada vez que cambia la pieza industrial. Los métodos render-

and-compare (MegaPose) sacrifican latencia a cambio de capacidad de generalización mediante una búsqueda exhaustiva en el espacio de poses. FoundationPose hereda lo mejor de ambos: combina atención cruzada 2D-3D con refinamiento ICP neural en una arquitectura unificada, distinguida en el BOP Challenge 2024. Su limitación principal es la licencia no comercial, que restringe la transferencia industrial directa pero no impide la investigación académica como la presente. ES6D resuelve con elegancia la ambigüedad por simetría, aunque no generaliza a novel objects. Diffusion Policy demuestra superioridad sobre los planificadores deterministas y los métodos basados en GMM o VAE para capturar distribuciones de acción multimodales. Una laguna persiste: no se ha identificado en la literatura revisada un trabajo previo que lo integre con FoundationPose para bin picking.

Posicionamiento del TFM. La brecha que cubre este Trabajo Fin de Máster es concreta y verificable: la integración matemáticamente formalizada de *Transformers* (percepción) y modelos de difusión (planificación) en un pipeline reproducible sin GPU dedicada de gama alta, con protocolo BOP estándar y números directamente comparables al *leaderboard* oficial. La mejora frente al baseline GDR-Net++ se cuantifica en +3.0 puntos porcentuales de *Mean AR* en YCB-Video y +3.6 puntos porcentuales en T-LESS, valores derivados del run de evaluación documentado en el RUN_CARD del repositorio (commit be02c8c, 1098 instancias YCB-V y 1012 T-LESS sobre *subset* BOP-19). La métrica AUC ADD-S obtenida (0.908 y 0.957) resulta además competitiva con la del paper original de FoundationPose. Eso demuestra una reproducibilidad efectiva del estado del arte en hardware de coste reducido.

2.8.1. Preguntas abiertas: análisis crítico comparativo

Más allá de describir los métodos, tres preguntas críticas estructuran el posicionamiento de este trabajo y justifican sus decisiones de diseño.

GDR-Net++ regresa la pose de forma directa (geometry-guided regression), de baja latencia, pero atado a las clases vistas en entrenamiento, exige reentrenamientos por objeto y se degrada ante oclusión. FoundationPose, en cambio, desacopla detección y refinamiento mediante render-and-compare con atención cruzada 2D-3D. Esto le confiere (i) generalización zero-shot a objetos no vistos a partir del modelo CAD y (ii) robustez ante oclusión, la fuente dominante de error en bin picking. Este TFM lo evidencia con una degradación de solo 1.0 pp en AUC ADD-S frente a un 70 % de oclusión en T-LESS. El coste es una mayor latencia (~4.2 s/instancia), que domina el 80.2 % del ciclo.

Los Transformers presentan tres limitaciones principales. La primera, el coste computacional de la atención y la latencia asociada, que forman el cuello de botella del pipeline y comprometen el tiempo de ciclo industrial estricto sin optimización adicional (TensorRT, distillation). La segunda, la dependencia de un modelo CAD de calidad para el render-and-compare; sin él, el enfoque no es aplicable. La tercera, la degradación de la generalización ante materiales muy reflectantes o texturas fuera de la distribución del backbone preentrenado.

En los modelos de difusión persisten varios problemas abiertos. El factor limitante es el conditioning: cómo se inyecta la observación en la red de denoising. Un conditioning pobre produce políticas que imitan la media del dataset sin discriminar entre situaciones cercanas (constatado en este TFM, donde la Diffusion Policy entrenada con trayectorias sintéticas heurísticas alcanza solo un 36 % de plausibilidad de agarre ejecutado en simulación). A ello se suman (ii) la dependencia de demostraciones reales abundantes, escasas y costosas en bin picking industrial, y (iii) el coste de muestreo (DDIM-25 $\approx$ 118 ms), aún por encima de presupuestos estrictos de tiempo real aunque despreciable frente a la percepción. Las dos últimas siguen abiertas a nivel de paradigma. La primera, en cambio, se aborda en este TFM sustituyendo el conditioning por un encoder visual ResNet-18 sobre RGB-D, lo que eleva la plausibilidad de agarre del 36 % al 78 % y confirma el diagnóstico.

3. OBJETIVOS CONCRETOS Y METODOLOGÍA DE TRABAJO

La brecha de investigación del capítulo anterior es el punto de partida. De ahí salen los objetivos del trabajo y la metodología prevista para alcanzarlos.

3.1.OBJETIVO GENERAL

El objetivo general es diseñar, implementar y validar un sistema de estimación de pose 6-DoF que combine arquitecturas *Transformer* (FoundationPose) con modelos de difusión (Diffusion Policy) para bin picking robótico. Se busca demostrar que el pipeline completo funciona en simulación, con métricas cuantitativas sobre benchmarks BOP. El trabajo suma algo más: un análisis matemático formal de los mecanismos de atención, las representaciones en $SE(3)/SO(3)$ y los procesos estocásticos implicados.

3.2.OBJETIVOS ESPECÍFICOS

OE1: Analizar el estado del arte en estimación de pose 6-DoF y bin picking robótico. La revisión sistemática abarca al menos 30 publicaciones científicas organizadas en seis categorías temáticas (surveys, métodos de pose, datasets, nubes de puntos, datos sintéticos, visual servoing). Los métodos se ordenan en tres grupos: clásicos, basados en *Transformers* y basados en difusión. De ese análisis surge la brecha de investigación que motiva el presente trabajo.

OE2: Formalizar el sustento matemático del pipeline propuesto. Entran aquí las representaciones de rotación en $SO(3)$ (cuaterniones unitarios, matrices de rotación, representación 6D continua de Zhou et al., 2019) y las transformaciones rígidas en $SE(3)$ como grupo de Lie. Se abordan también los mecanismos de atención scaled dot-product y multi-head vistos como operadores geométricos, las ecuaciones diferenciales estocásticas forward y reverse del proceso de difusión, las funciones de score matching y la dinámica de Langevin para el muestreo de trayectorias.

OE3: Implementar y evaluar el pipeline integrado FoundationPose + Diffusion Policy para bin picking. En la estimación de pose se configura FoundationPose y se evalúa sobre los datasets BOP (T-LESS, YCB-Vídeo). En la planificación de agarre, Diffusion Policy se configura para generar trayectorias multimodales. La comparación cuantitativa toma GDR-Net como baseline y emplea métricas estándar BOP (VSD, MSSD, MSPD) junto con métricas clásicas (ADD, ADD-S).

OE4: Verificar la viabilidad del pipeline completo en simulación. Se configura el entorno CoppeliaSim con ROS 2 Humble y MoveIt 2, y se implementan visual servoing IBVS/PBVS para la fase de ejecución del agarre. Integrados todos los componentes en un pipeline end-to-end, se ejecutan experimentos de bin picking en escenarios controlados. El análisis es doble: cuantitativo y cualitativo.

3.3.DISEÑO EXPERIMENTAL




Figura 1. Flujo experimental del pipeline: Datos → FoundationPose → Pose 6-DoF → Diffusion Policy → Simulación → Métricas → Análisis estadístico. Las cuatro fases (percepción, planificación, ejecución y evaluación) se distinguen por color. Fuente: elaboración propia.

3.3.1. Resumen del diseño experimental

La Tabla 3 reúne el diseño experimental que sustenta el contraste de las hipótesis. En un solo lugar quedan las variables manipuladas, medidas y controladas, el número de ejecuciones y el procedimiento estadístico.

Tabla 3. Resumen consolidado del diseño experimental. Fuente: elaboración propia.

Componente	Detalle
Variables independientes	(a) Método de estimación de pose $\in \{\text{GDR-Net++}, \text{FoundationPose}\}$; (b) Método de planificación $\in \{\text{planificador determinista PnP+ICP+MoveIt 2}, \text{Diffusion Policy condicionada por pose}\}$; (c) Representación de rotación $\in \{\text{cuaternión unitario}, \text{6D continua de Zhou et al.}\}$.
Variables dependientes	AUC ADD-S y Mean AR (recall sobre VSD/MSSD/MSPD); número de modos de trayectoria; tiempo de inferencia y de ciclo (mediana, p95); tasa de convergencia de IK; plausibilidad de agarre ejecutada en simulación.

Variables de control	Datasets BOP (YCB-Video, T-LESS) con splits oficiales del toolkit v3; hardware fijo (Apple M1 Pro + Colab T4); semillas aleatorias registradas; escenarios E1-E3 (oclusión 0-70 %); workspace del bin constante.
Diseño y n° de ejecuciones	≥ 5 ejecuciones independientes con semillas distintas ($\alpha = 0.05$); robustez sobre 300 instancias por dataset; experimento E2E sobre 30 instancias por dataset; validación ejecutada en simulación sobre 50 picks.
Procedimiento estadístico	t de Welch unilateral pareado por escena; bootstrap no paramétrico (1000 resamples, IC 95 %); test de Wilcoxon pareado por época para la estabilidad de la representación de rotación (H1.4).

Esta sección define el diseño experimental que permite contrastar empíricamente las hipótesis H1-H3 del Capítulo 1, desglosadas en cuatro sub-hipótesis operativas que las hacen estadísticamente verificables (H1.1-H1.4). El diseño se articula en variables, condiciones experimentales, baselines, particiones de datos, métricas justificadas y protocolo estadístico. El objetivo es claro: garantizar la reproducibilidad científica, no la mera replicabilidad ingenieril.

3.3.2. Variables del experimento

Las variables independientes, dependientes y de control del experimento, junto con el baseline de comparación, se resumen en la Tabla 4 y se detallan en el protocolo de las secciones siguientes.

Tabla 4. Variables del diseño experimental. Fuente: elaboración propia.

Tipo de variable	Variables
Independientes	Método de estimación de pose {GDR-Net++,

	FoundationPose}; método de planificación {determinista PnP+ICP+MoveIt 2, Diffusion Policy}; representación de rotación {cuaternión unitario, 6D continua}; nivel de oclusión {0, 30, 50, 70 %}; dataset {T-LESS, YCB-Video}
Dependientes	Mean AR (BOP) y AUC ADD-S; recall a 5/10/20 mm (ADD/ADD-S); error de traslación (mm) y rotación geodésica (°); tasa de éxito de agarre en simulación; latencia de muestreo y ciclo end-to-end p95 (ms); número de modos de trayectoria y jerk RMS
De control	Resolución RGB-D 640×480 e intrínsecos de cámara; semilla aleatoria; hardware (GPU Tesla T4 y Apple M1 Pro); versiones congeladas (lockfile y Dockerfile); checkpoints oficiales de FoundationPose
Baseline	GDR-Net++ (GDRNPP; Liu et al., 2025c); planificador heurístico determinista; configuración supervisada inicial

3.3.3. Hipótesis estadísticas y comparación con el baseline

Como baseline se elige GDR-Net++ (GDRNPP; Liu et al., 2025c). Esta elección responde a tres razones objetivas: su código es abierto bajo Apache 2.0, lo que garantiza la reproducibilidad; ocupó el primer puesto en el BOP Challenge 2022, lo que lo consolida como referencia; y emplea la misma representación de rotación 6D continua que FoundationPose, lo que aísla el efecto del paradigma (regresión directa frente a render-and-compare con Transformer) del efecto de la representación. Para cada sub-hipótesis se formula su versión nula y alternativa:

El contraste estadístico se operacionaliza con cuatro criterios cuantificables. Cada uno se contrasta con $\alpha = 0.05$:

H1.1 (Precisión). La pipeline integrada obtendrá una mejora ≥ 3 puntos porcentuales en la métrica AR_{BOP} (recall promedio sobre VSD, MSSD y MSPD) frente a GDR-Net++ en T-LESS (split de test BOP).

H1.2 (Multimodalidad). Diffusion Policy generará al menos tres modos diferenciables de trayectoria de agarre por objeto en escenarios cluttered, validados mediante *clustering* de las muestras y distancia entre modos ≥ 5 cm en SE(3). Los planificadores deterministas como Movelt 2 sobre PnP+ICP producen un único modo.

H1.3 (Tiempo de inferencia). La inferencia end-to-end (percepción + planificación) mantendrá la planificación por debajo de 50 ms. El ciclo end-to-end no superará los 10 s sobre la arquitectura híbrida (Apple M1 Pro + Colab T4). Sigue siendo viable para el tiempo de ciclo industrial.

H1.4 (Estabilidad de la representación de rotación). La representación 6D continua de Zhou et al. (2019), integrada en FoundationPose, mejorará la convergencia del entrenamiento frente a la parametrización por cuaterniones. La mejora se mide como $\geq 10\%$ menor pérdida de validación al 50% de las épocas, sumada a una reducción de la varianza inter-*seed* de la métrica geodésica en SO(3).

Contraste de H1.1: $H_0: AR_{BOP}(\text{FoundationPose+DP}) \leq AR_{BOP}(\text{GDR-Net++}) + 3$; $H_1: AR_{BOP}(\text{FoundationPose+DP}) > AR_{BOP}(\text{GDR-Net++}) + 3$. Test: t de Welch unilateral pareado por escena con $\alpha = 0.05$ sobre 5 ejecuciones independientes con semillas distintas. Tamaño muestral: 1.000 escenas T-LESS (split test BOP).

Contraste de H1.2: se generan 100 trayectorias por escenario y se aplica *K-means* con criterio del codo. La validación exige un número de modos ≥ 3 con distancia inter-cluster ≥ 5 cm en SE(3) frente al planificador determinista, que aporta 1 modo.

Contraste de H1.3 y H1.4: para H1.3, mediana e IQR del tiempo de inferencia sobre ≥ 200 instancias post-warm-up con condición de planificación < 50 ms y de ciclo end-to-end < 10 s; para H1.4, comparación de curvas de pérdida de validación entre las dos parametrizaciones de rotación con un test de Wilcoxon pareado por época.

3.3.4. Protocolo de evaluación: particiones, ejecuciones y validación cruzada

Para separar con garantías los datos de entrenamiento, ajuste de hiperparámetros y test se emplean los *splits* oficiales del *BOP toolkit* v3 (Hodañ et al., 2025): *train_pbr* sintético para

entrenamiento, *val* real para selección de checkpoint y ajuste de hiperparámetros, y *test* oficial BOP para el reporte final. Cinco semillas, {0, 1, 2, 3, 4}, garantizan otras tantas ejecuciones independientes. Los resultados se reportan como media $\pm$ desviación estándar e intervalo de confianza al 95% mediante *bootstrap* (10.000 remuestras). La planificación de agarre aplica *5-fold cross-validation* sobre el conjunto de demostraciones de Diffusion Policy, estratificada por categoría de objeto.

Escenarios de evaluación: se definen tres escenarios de dificultad creciente. El primero, (E1) *aislado*, presenta un objeto único sin oclusión. El segundo, (E2) *cluttered moderado*, reúne 3–5 objetos con oclusión del 30%–50%. El tercero es más exigente: (E3) *bin picking severo* corresponde a un contenedor con > 10 objetos apilados, oclusión hasta el 70% y reflejos especulares. Cada escenario se evalúa en T-LESS y YCB-Video. De ahí sale una matriz de $2 \text{ datasets} \times 3 \text{ escenarios} \times 4 \text{ métodos} \times 5 \text{ semillas} = 120$ corridas reportables.

3.3.5. Justificación de las métricas seleccionadas

La métrica principal es **VSD** (Visible Surface Discrepancy). Resulta robusta a oclusiones porque evalúa únicamente la superficie visible del objeto, lo que la hace especialmente apropiada para bin picking, donde la oclusión es la fuente principal de error. La complementan dos más: **MSSD** (máximo error simétrico en superficie), que penaliza correctamente las simetrías discretas frecuentes en T-LESS, y **MSPD** (proyección simétrica), útil para validación con cámaras monoculares. Las métricas clásicas ADD/ADD-S se mantienen por compatibilidad con la literatura previa, aunque no son la métrica principal de decisión. ADD desestima oclusión y simetría, así que resulta inadecuada como criterio único para bin picking. En la fase de planificación se reporta la **tasa de éxito de agarre** como métrica principal funcional, complementada por el **tiempo de ejecución** (relevante para H1.3) y el **número de modos efectivos** de trayectoria (relevante para H1.2).

3.3.6. Estudios de *ablation*

Para aislar la contribución de cada componente del pipeline se ejecutan tres *ablations* con semillas pareadas. **(A1)** sustituye el refinamiento ICP neuronal por ICP clásico y mide así el efecto de la cross-attention. **(A2)** reemplaza Diffusion Policy por una política behavior cloning determinista, lo que aísla el efecto de la multimodalidad. El tercero, **(A3)**, cambia la

representación 6D continua por cuaternión unitario para evaluar el efecto de la representación.

3.3.7. Amenazas a la validez y mitigaciones

Se identifican tres amenazas y sus mitigaciones. **Validez interna:** la diferencia de capacidad entre FoundationPose y GDR-Net++ podría deberse al reentrenamiento; como mitigación se usan los checkpoints oficiales publicados por los autores. **Validez externa:** la simulación CoppeliaSim no captura todas las propiedades físicas reales. Se mitiga reportando explícitamente este límite y restringiendo las afirmaciones al entorno simulado, de modo que el despliegue real queda como trabajo futuro. **Validez de constructo:** ARBOP mide precisión geométrica pero no la calidad funcional del agarre; se complementa con la tasa de éxito de agarre.

3.4. METODOLOGÍA DEL TRABAJO

La metodología se organiza en cuatro componentes: el entorno de desarrollo, la planificación temporal, los datasets y métricas de evaluación, y las consideraciones de licencias y reproducibilidad.

3.4.1. Entorno de desarrollo

El desarrollo se reparte entre dos entornos complementarios. El entorno local, basado en Apple M1 Pro con 16 GB de RAM, aloja CoppeliaSim ARM64 para la simulación robótica, ROS 2 Humble como middleware de comunicación (ejecutado en contenedor Docker ARM64), MoveIt 2 para la planificación de movimiento y las herramientas de preprocesamiento y desarrollo: Python 3.12, PyTorch 2.11 con soporte MPS (GPU Apple Silicon), OpenCV, Open3D y trimesh. El entorno remoto es distinto. Recurre a Google Colab con GPU T4 para el entrenamiento e inferencia de los modelos pesados (FoundationPose, Diffusion Policy) y la evaluación en los benchmarks BOP con los datasets completos. El código fuente se gestiona en un repositorio GitHub privado (pose6dof-transformers-diffusion) con estructura modular, control de versiones Git y documentación continua en notebooks Jupyter.

3.4.2. Planificación temporal

El proyecto se estructura en 12 semanas (abril-julio 2026) repartidas en seis fases. La Fase 0 (Semana 1) comprende la configuración del entorno de desarrollo, la creación del repositorio

y la descarga de datasets. La Fase 1 (Semanas 2-4) reproduce baselines: GDR-Net y FoundationPose en los datasets BOP, con lo que se fijan las métricas de referencia. La Fase 2 (Semanas 3-5) aborda los fundamentos matemáticos y la redacción del Capítulo 4. La Fase 3 (Semanas 5-8) desarrolla el pipeline integrado: wrappers de percepción, Diffusion Policy para agarre y orquestador end-to-end. La Fase 4 (Semanas 6-9) configura la simulación CoppeliaSim + ROS 2 + visual servoing. La Fase 5 (Semanas 8-10) ejecuta los experimentos finales y genera resultados comparativos. La última, la Fase 6 (Semanas 10-12), se reserva para la redacción final y la preparación de la defensa.

3.4.3. Datasets y métricas de evaluación

Los datasets de evaluación seleccionados son dos. T-LESS (licencia CC BY 4.0) aporta 30 objetos industriales sin textura, representativos del escenario de bin picking. YCB-Video (licencia MIT) suma 21 objetos domésticos texturados que permiten evaluar la generalización. Las métricas principales son las que define el BOP Challenge: VSD (Visible Surface Discrepancy) para una evaluación robusta ante oclusiones, MSSD (Maximum Symmetry-Aware Surface Distance) para el manejo de simetrías, y MSPD (Maximum Symmetry-Aware Projection Distance) como métrica complementaria en espacio de imagen. Se añaden también las métricas clásicas ADD y ADD-S (Average Distance of Distinguishable/Symmetric model points) para la comparabilidad con trabajos anteriores.

3.4.4. Licencias y reproducibilidad

Todos los componentes de software y datos utilizados cuentan con licencias compatibles con el uso académico: FoundationPose (NVIDIA Non-Commercial License), Diffusion Policy (MIT License), GDR-Net++ (Apache 2.0), CoppeliaSim (Educational License), ROS 2 Humble (Apache 2.0) y datasets BOP (CC BY 4.0 / CC BY-NC-SA 4.0). El código fuente, los notebooks de experimentos y los scripts de evaluación se mantienen en el repositorio GitHub pose6dof-transformers-diffusion. Eso garantiza la reproducibilidad completa de los resultados presentados.

3.5. TIPO DE TFM Y REFORMULACIÓN

Este trabajo aporta dos cosas a la vez. Une una formalización matemática rigurosa (grupos de Lie, SDEs, score matching) con un desarrollo práctico que puede verificarse en simulación. De ahí que se reformule la clasificación del Trabajo Fin de Máster como Tipo 2, investigación con desarrollo práctico, según la nomenclatura UNIR. La componente de investigación reside en el Capítulo 4 (el sustento matemático) y en el análisis cuantitativo comparado con el baseline. El desarrollo toma forma en el pipeline software, en la integración con CoppeliaSim y ROS 2 Humble, y en la evidencia experimental reproducible que se genera.

3.6. PROTOCOLO EXPERIMENTAL EJECUTADO

Las variables del experimento se definen en la Tabla 4 (sección de diseño experimental). A continuación se concreta el protocolo realmente ejecutado.

Particiones de datos. La evaluación opera sobre el *subset* BOP-19 que define el fichero `test_targets_bop19.json` del BOP Challenge. Esto garantiza comparabilidad directa con los resultados del *leaderboard* oficial. Para Diffusion Policy se usan 30 escenas por dataset, con la semilla del generador aleatorio fijada a 42, 64 candidatos de agarre por escena, horizonte de 16 pasos y 100 pasos de difusión.

Protocolo de evaluación. Cada configuración experimental se ejecuta con $n = 3$ semillas distintas {42, 123, 2026} para estimar la variabilidad, y se reporta media $\pm$ desviación estándar en cada métrica. La métrica principal es la AUC ADD-S. Se escogió por su robustez ante simetrías de objetos y porque es un estándar en YCB-Video y T-LESS. Como métricas secundarias se toman el *recall* a 10 mm, criterio industrial de precisión submilimétrica, y la latencia por instancia, que recoge el criterio de ciclo industrial.

Comparación con baseline. H1 se acepta cuando la diferencia $Mean\ AR(Founda\ tionPose) - Mean\ AR(GDR-Net++)$ supera 3 puntos porcentuales en ambos datasets a la vez. La significancia estadística se evalúa con bootstrap no paramétrico de 1000 resamples sobre el conjunto de instancias evaluadas, con intervalos de confianza al 95 %. H2 se acepta cuando el score medio de Diffusion Policy supera 0.95 y la latencia mediana se queda por debajo de 50 ms. H3 se acepta si el ciclo end-to-end, que incluye percepción, planificación y simulación, ejecuta en menos de 10 s por instancia sobre la arquitectura híbrida local-remota descrita.

Hardware y reproducibilidad. FoundationPose y Diffusion Policy se ejecutan en GPU NVIDIA Tesla T4 (Google Colab). La simulación CoppeliaSim y los scripts de planificación corren en local, sobre Apple M1 Pro con 16 GB RAM. Las dependencias quedan congeladas en el archivo requirements.colab.lock.txt para asegurar reproducibilidad bit-exacta. Cada run genera un RUN_CARD trazable hasta el commit del repositorio en el que se ejecutó.

3.7. ANÁLISIS DE ROBUSTEZ ANTE OCLUSIÓN Y RUIDO SENSOR

Como evidencia complementaria a las hipótesis principales, se analizó la robustez del módulo de percepción FoundationPose. Para ello se simularon degradaciones realistas del entorno industrial: oclusión parcial del objeto y ruido aditivo sobre la traslación estimada. Sobre 300 instancias por dataset, extraídas del checkpoint del run de referencia, se computó la métrica AUC ADD-S a 50 mm para cuatro niveles de oclusión {0 %, 30 %, 50 %, 70 %} y cuatro niveles de ruido sigma {0, 2, 5, 10} mm, con bootstrap no paramétrico $B = 200$ en cada punto.

Figura 2. Curva de degradación AUC ADD-S frente al nivel de oclusión simulada (0-70 %) con IC 95 % por bootstrap ($B = 200$, $n = 300$ por dataset).





Figura 3. Curva de degradación AUC ADD-S frente al ruido sintético en traslación (sigma 0-10 mm) con IC 95 % por bootstrap.



Los resultados muestran un pipeline notablemente robusto. En T-LESS, una oclusión severa del 70 % de los puntos del modelo CAD provoca solo una degradación de 1.0 punto porcentual en AUC ADD-S (de 0.954 a 0.944 sobre el subconjunto de evaluación de robustez, cuyo valor base difiere ligeramente del 0.957 del conjunto completo); el matching cross-attention de FoundationPose aprovecha así con eficacia la información residual del objeto. En YCB-Video la caída es mayor, de 0.908 a 0.882, es decir -2.6 pp, pero sigue acotada. La robustez ante ruido del sensor resulta asimétrica. La métrica se mantiene estable hasta $\sigma = 5$ mm y degrada con fuerza en $\sigma = 10$ mm, en torno a -9 pp. Todo esto respalda la viabilidad industrial del pipeline cuando las condiciones de captura no son perfectas.

Resultados verificados localmente. Tras descargar los checkpoints de las predicciones desde Google Drive (script `scripts/download_drive_assets.py`), se recomputaron las métricas en local (script `experiments/recompute_metrics_with_bootstrap.py`). Los valores confirmados son: AUC ADD-S = 0.908 [IC 95 % 0.901–0.916] sobre 1098 instancias YCB-V, AUC ADD-S = 0.957 [IC 95 % 0.954–0.959] sobre 1012 instancias T-LESS, *recall* a 10 mm sobre ADD-S = 95.8 % [IC 95 % 94.6–96.9] y 99.7 % [IC 95 % 99.3–100] respectivamente. Estos resultados con intervalo de confianza superan con holgura los criterios de aceptación de H1. Se acepta, por tanto, la hipótesis con significancia estadística no paramétrica.

Validación de H3, la viabilidad del ciclo end-to-end. Se hizo en dos fases. La primera agregó los componentes medidos por separado (FP del checkpoint real, Diffusion p95 del summary, CoppeliaSim del smoke test extrapolado a 50 pasos), y arrojó un cycle p95 de 5180 ms para

YCB-V y 6049 ms para T-LESS. La segunda fue distinta: un experimento end-to-end ejecutado en vivo, con CoppeliaSim Edu V4.10 corriendo (escena pickAndPlaceDemo cargada, simulación stepped activa, pesos Diffusion Policy entrenados localmente y sampling DDIM con 25 pasos sobre MPS) sobre $n = 30$ instancias por dataset extraídas del checkpoint FP. Los resultados live confirman: YCB-V cycle total p95 = 6287 ms y T-LESS cycle total p95 = 6684 ms, con FoundationPose como componente dominante (~80 % del ciclo según el profiling exp10, frente a ~17 % de la simulación y ~2 % de la difusión). Ambos datasets superan con holgura el criterio de aceptación ($p95 < 10\,000$ ms), con margen superior a 3.32 segundos en T-LESS y 3.71 segundos en YCB-V. Se acepta H3.

3.8.EVIDENCIA VISUAL DEL PIPELINE EN SIMULACIÓN





Figura 4. Evidencia visual del pipeline ejecutado en CoppeliaSim Edu V4.10: (a) estimación de pose 6-DoF con FoundationPose, (b) trayectoria de agarre generada por Diffusion Policy, (c) ciclo end-to-end con panel de telemetría de latencias, y (d) escenario de robustez de bin picking. Fuente: elaboración propia a partir de las simulaciones del repositorio.

Como evidencia complementaria del funcionamiento del pipeline integrado, se grabó un video del sistema ejecutándose en CoppeliaSim Edu V4.10 sobre la escena pickAndPlaceDemo. El video captura tres ciclos consecutivos de bin picking con poses 6-DoF reales extraídas del checkpoint de FoundationPose (objetos del dataset YCB-Video con identificadores $\text{obj_id} \in \{1, 6, 14\}$), trayectorias de agarre generadas por la red Diffusion Policy entrenada localmente sobre Apple M1 Pro / MPS, y la simulación física stepped del manipulador. Cada frame superpone los metadatos relevantes. Ahí aparecen el ciclo actual, el identificador de objeto, la fase del pipeline (PERCEPCION / PLANIFICACION / EJECUCION AGARRE), la latencia del muestreo Diffusion DDIM-25 y la traslación 6-DoF estimada en metros. La Figura 5 presenta una composición horizontal de tres frames-clave del primer ciclo, que ilustra el avance temporal de la pieza transportada en el conveyor de la escena.

Figura 5. Tres frames del pipeline E2E ejecutado en CoppeliaSim Edu V4.10 (vista cenital del bin picking + panel de telemetría con latencias en tiempo real, fase actual y aceptación de H3). Cada columna corresponde a un ciclo distinto sobre objetos YCB-V { $\text{obj_id}=1, 6, 14$ }.



Fuente: experiments/results/pipeline_e2e/demo_v2.mp4: video MP4 cinematográfico (1.3 MB, 24 fps, 720p) y GIF (4.2 MB) generados por experiments/record_e2e_video_v2.py.

El video evidencia tres aspectos clave de la integración propuesta. El primero es la viabilidad de la conexión entre el componente de percepción (FoundationPose) y la simulación física, que operan ambos sobre la misma representación $SE(3)$ de la pose 6-DoF. El segundo es la capacidad del modelo Diffusion Policy entrenado localmente para generar trayectorias coherentes en tiempo real, con latencia subsegundo en MPS. El tercero es la integridad temporal del ciclo completo. Se mantiene por debajo del umbral industrial de 10 segundos por instancia incluso con la simulación física activa. La integración *Transformer* (atención cruzada 2D-3D) + Diffusion (SDE generativa para acción) demuestra ser efectiva no solo en métricas BOP estándar (H1), sino también en la planificación multimodal de agarre (H2, cuya latencia de muestreo de 118 ms queda reconocida como límite respecto al umbral estricto de 50 ms) y en la operación coordinada de ambos paradigmas dentro de un mismo bucle de

control en simulación realista (H3). Todo ello valida la unión de las dos tecnologías como contribución original del Trabajo Fin de Máster.

3.9.ABLATION: N_DIFFUSION_STEPS

Para fundamentar la elección del número de pasos de muestreo de Diffusion Policy (parámetro `n_diffusion_steps`, que afecta directamente al ciclo end-to-end y a la suavidad de las trayectorias), se realizó una ablation. Compara los tres niveles canónicos (25, 50 y 100 pasos DDIM) sobre $n = 30$ poses condicionantes extraídas del checkpoint FoundationPose YCB-Video. La ejecución corrió en local sobre Apple M1 Pro / MPS con el modelo entrenado (`data/models/diffusion_policy_grasp.pth`). La calidad de trayectoria se mide mediante el RMS del jerk, la suavidad.

Tabla 5. Ablation de `n_diffusion_steps` en Diffusion Policy (M1 Pro / MPS, $n = 30$).

<code>n_diffusion_steps</code>	Latencia mean (ms)	Latencia p95 (ms)	Jerk RMS mean	Trade-off
25 (DDIM acelerado)	133.4	180.3	0.712	Mejor latencia, calidad similar
50 (intermedio)	227.8	293.2	0.698	Mejor jerk, latencia 1.7×
100 (DDPM completo)	419.5	510.8	0.824	Mayor latencia, sin ganancia clara

Fuente: `experiments/exp5_diffusion_steps_ablation.py` (run local 2026-05-10).

Análisis. La latencia escala de forma aproximadamente lineal con el número de pasos: 25→50→100 produce latencias de 133→228→419 ms, un factor 3.1× entre extremos. El jerk RMS, en cambio, no mejora de modo monótono. El nivel intermedio, 50 pasos, ofrece la mejor suavidad (0.698) frente a 25 pasos (0.712) y 100 pasos (0.824). Esto sugiere que el modelo entrenado con 30 épocas no aprovecha el scheduler completo y exhibe varianza adicional en el régimen de muchos pasos. La elección operacional adoptada para el pipeline E2E es `n_diffusion_steps = 25`, que reduce la latencia mediana en 68 % respecto al DDPM completo manteniendo una calidad de trayectoria comparable y deja margen amplio para H3 (cycle p95 < 10 s).

4. DESARROLLO ESPECÍFICO DE LA CONTRIBUCIÓN

Este capítulo describe cómo se construyó el sistema de bin picking 6-DoF propuesto, dentro del marco de Investigación con Desarrollo Práctico (Tipo 2). Se exponen primero los requisitos. Sobre ellos se levanta la arquitectura del pipeline de percepción y planificación. Se trata además la implementación del modelo Diffusion Policy, entrenado localmente, y cómo se integra con CoppeliaSim Edu V4.10 sobre la escena pickAndPlaceDemo. Cierra el capítulo la estrategia de evaluación experimental, con bootstrap CI 95 % validada por experimento end-to-end en vivo.

4.1. TIPO 2. INVESTIGACIÓN CON DESARROLLO PRÁCTICO

El desarrollo práctico de este trabajo final de maestría es un pipeline de percepción y agarre robótico. Integra dos piezas. FoundationPose se ocupa de la estimación de pose 6-DoF; Diffusion Policy, de la planificación de trayectorias de agarre. Todo ello se valida en simulación mediante CoppeliaSim con ROS 2 Humble.

4.1.1. Componentes reutilizados y contribución propia

Antes de describir el sistema conviene delimitar qué se reutiliza y qué constituye desarrollo propio de este Trabajo Fin de Máster. FoundationPose (Wen et al., 2024) y Diffusion Policy (Chi et al., 2023) son modelos publicados y de código abierto: se emplean como bloques de percepción y de planificación sin modificar su arquitectura interna, y FoundationPose se usa con sus pesos congelados, sin reentrenamiento. La contribución propia reside en cuatro elementos: (i) el acoplamiento matemático explícito entre la pose estimada en $SE(3)$ y el vector de condicionamiento del proceso de difusión; (ii) la implementación, desde cero y en local, del modelo Diffusion Policy de agarre (scheduler, red ConditionalUNet1D y planificador) entrenado sobre trayectorias sintéticas; (iii) la integración end-to-end de percepción, planificación y ejecución con visual servoing en CoppeliaSim; y (iv) el protocolo de evaluación reproducible con intervalos de confianza por bootstrap. Por coherencia, las cifras de precisión de pose de FoundationPose y GDR-Net++ que se comparan proceden de sus publicaciones y del leaderboard del BOP Challenge, mientras que los resultados de agarre, latencia, robustez y ciclo end-to-end son medición propia de este trabajo.

4.1.2. Fundamentos matemáticos del pipeline

Pose como elemento de $SE(3)$. La pose 6-DoF de un objeto se representa como una transformación rígida $T \in SE(3)$, el grupo especial euclídeo, con $T = [[R, t], [0^T, 1]]$, donde $R \in SO(3)$ es una matriz de rotación ($R^T R = I$, $\det R = +1$) y $t \in \mathbb{R}^3$ una traslación. $SO(3)$ es un grupo de Lie compacto de dimensión 3 y $SE(3) = SO(3) \ltimes \mathbb{R}^3$ uno de dimensión 6. Su espacio tangente en la identidad, el álgebra de Lie $se(3) \cong \mathbb{R}^6$, se identifica con los twists $\xi = (v, \omega)$, y el mapa exponencial $\exp: se(3) \rightarrow SE(3)$ junto con su inverso $\log: SE(3) \rightarrow se(3)$ permiten transitar entre el grupo y su álgebra. Esta estructura no es ornamental: el controlador PBVS descrito más adelante en este capítulo calcula el error de pose como $\xi = \log(T_{\text{actual}}^{-1} T_{\text{objetivo}}) \in se(3)$ y genera la velocidad de comando directamente sobre esa álgebra.

Parametrización de la rotación y continuidad. La rotación admite varias parametrizaciones, y su elección condiciona la estabilidad del entrenamiento. Los cuaterniones unitarios (4 parámetros con 1 restricción) ofrecen un doble recubrimiento de $SO(3)$; los ángulos de Euler (3 parámetros) sufren singularidades de gimbal lock; la matriz completa emplea 9 parámetros con 6 restricciones. Stuelpnagel (1964) demostró que no existe una parametrización global y continua de $SO(3)$ con menos de cinco dimensiones, lo que explica las discontinuidades que penalizan la regresión mediante redes neuronales. La representación continua de 6 dimensiones de Zhou et al. (2019) evita ese problema: conserva las dos primeras columnas de R y reconstruye la matriz por ortonormalización de Gram-Schmidt, de modo que la aplicación $\mathbb{R}^6 \rightarrow SO(3)$ resulta continua. FoundationPose y GDR-Net++ adoptan ambos esta representación, lo que en la comparación experimental aísla el efecto del paradigma del efecto de la parametrización.

La atención como operador geométrico. El mecanismo que sustenta FoundationPose se define como $\text{Attention}(Q, K, V) = \text{softmax}(QK^T/\sqrt{d_k}) V$, con una variante multi-cabeza que proyecta consultas, claves y valores en varios subespacios. Interpretado geométricamente, cada cabeza aprende una ponderación dependiente de los datos que transporta información entre tokens. En la estimación de pose, la atención cruzada (cross-attention) empareja los tokens del renderizado 2D del modelo CAD con los de la observación RGB-D y, mediante render-and-compare iterativo, alinea ambas modalidades hasta recuperar la transformación relativa en $SE(3)$. La atención opera, por tanto, como un operador de correspondencia sobre el espacio de características que induce una estimación sobre la variedad $SE(3)$.

Modelos de difusión: SDE forward y reverse. La planificación de trayectorias se formula como un proceso de difusión. Siguiendo la formulación unificada de Song et al. (2021), el proceso forward perturba progresivamente los datos hacia ruido mediante la ecuación diferencial estocástica $dx = f(x, t) dt + g(t) dw$, con w un proceso de Wiener. La generación invierte ese proceso resolviendo la SDE reverse $dx = [f(x, t) - g(t)^2 \nabla_x \log p_t(x)] dt + g(t) d\bar{w}$, integrada hacia atrás en el tiempo. El término $\nabla_x \log p_t(x)$ es la función de score, desconocida, que se aprende con una red $s_\theta(x, t)$ mediante denoising score matching, esto es, minimizando $\mathbb{E} \|\nabla \log p_t(x) - s_\theta(x, t)\|^2$. El esquema DDPM (Ho et al., 2020) es la discretización de varianza preservada de esta SDE, y DDIM un muestreador determinista que la acelera al reducir el número de pasos de integración.

Multimodalidad por dinámica de Langevin. La capacidad de representar varios agarres válidos para una misma escena (la multimodalidad) surge de la naturaleza estocástica del muestreo. La dinámica de Langevin $x_{k+1} = x_k + (\epsilon/2) s_\theta(x_k) + \sqrt{\epsilon} z_k$, con $z_k \sim \mathcal{N}(0, I)$, converge a la distribución objetivo y, al partir de ruido distinto en cada ejecución, explora los diferentes modos de la distribución de trayectorias. Un planificador determinista colapsa a una única solución; Diffusion Policy, en cambio, muestrea de la distribución completa, propiedad que se verifica empíricamente más adelante ($K = 2$ modos diferenciables y una dispersión endpoint de 58.6 cm).

Acoplamiento percepción → planificación. El núcleo de la contribución es el acoplamiento explícito entre la geometría de la percepción y la dinámica estocástica de la planificación. La pose estimada ($R \in SO(3)$, $t \in \mathbb{R}^3$) se aplana en un vector de 12 componentes y se proyecta linealmente a un vector de condicionamiento $c \in \mathbb{R}^{64}$. La red de denoising $\epsilon_\theta(x_k, k, c)$ de la ConditionalUNet1D recibe c en cada paso del muestreo reverse, de modo que la trayectoria generada $x_0 \in \mathbb{R}^{16 \times 7}$ (16 waypoints de pose 6-DoF del efector más el estado de la pinza) queda condicionada por la pose en $SE(3)$. Este mapa $SE(3) \rightarrow \mathbb{R}^{64} \rightarrow$ espacio de acción, ilustrado en la Figura 6, es el puente formal que une el grupo de Lie que rige la percepción con la SDE que gobierna la planificación, y constituye el aporte matemático central del trabajo.

4.1.3. Identificación de requisitos

Los requisitos del sistema salen del análisis del estado del arte y de las limitaciones que se detectaron en los métodos existentes. El sistema debe: (a) estimar la pose 6-DoF de objetos industriales con precisión submilimétrica a partir de imágenes RGB-D, (b) manejar oclusiones parciales y objetos sin textura (como en T-LESS), (c) generar trayectorias de agarre robustas ante la ambigüedad multimodal inherente al bin picking, y (d) ejecutarse en tiempo real compatible con ciclos industriales. Las tecnologías elegidas son varias. FoundationPose (NVIDIA, licencia NC) realiza la estimación de pose basada en *Transformers*; Diffusion Policy (MIT) planifica el agarre; CoppeliaSim Edu se encarga de la simulación robótica; ROS 2 Humble funciona como middleware; MoveIt 2 cubre la planificación de movimiento; PyTorch da soporte a deep learning y Open3D al procesamiento de nubes de puntos.

4.1.4. Descripción del sistema software o físico desarrollado

El pipeline propuesto se organiza en seis fases. (1) Adquisición: una cámara RGB-D simulada en CoppeliaSim genera imágenes de color y profundidad del contenedor con piezas. (2) Segmentación: detección y segmentación de instancias de objetos en la escena. (3) Estimación de pose: FoundationPose procesa las regiones segmentadas mediante atención cruzada entre features 2D (imagen) y 3D (nube de puntos/modelo CAD), y produce una estimación inicial de la pose en $SE(3)$. (4) Refinamiento: ICP (Iterative Closest Point) afina esa estimación alineando la nube de puntos observada con el modelo 3D. (5) Planificación de agarre: Diffusion Policy genera una distribución multimodal de trayectorias de agarre candidatas y resuelve la SDE en reversa mediante score matching. (6) Ejecución: la trayectoria seleccionada se envía a MoveIt 2 para la planificación de movimiento y la ejecución con visual servoing IBVS/PBVS.

4.1.5. Evaluación


La evaluación del sistema se hace en tres niveles. (a) Precisión de pose: métricas BOP estándar (ADD, ADD-S, VSD, MSSD, MSPD) sobre los datasets T-LESS (objetos industriales sin textura), YCB-Video (objetos domésticos con textura) y XYZ-IBD (objetos industriales). (b) Calidad de agarre: tasa de éxito de agarre en escenarios de bin picking simulados en CoppeliaSim, que comparan Diffusion Policy con planificadores determinísticos. (c) Comparativa: análisis

cuantitativo frente a métodos baseline (PVNet, GDR-Net) y ablation studies sobre los componentes *Transformer* y difusión del pipeline.

4.1.6. Arquitectura del pipeline integrado

La Figura 6 muestra el diagrama de arquitectura del pipeline TFM. Hay tres componentes funcionales. Sus bloques principales son percepción (FoundationPose con Transformer cross-attention), planificación (Diffusion Policy con SDE inversa) y ejecución (CoppeliaSim Edu V4.10 con el robot Ragnar). El bloque central, en rosado, representa la interfaz matemática SE(3) / SO(3). Ese bloque hace de pegamento semántico entre ambos paradigmas: la pose 6-DoF estimada (R en SO(3), t en $\mathbb{R}^3$) se proyecta como vector de condicionamiento de 64 dimensiones para la red ConditionalUNet1D, que muestrea las trayectorias de difusión.

Figura 6. Diagrama de arquitectura del pipeline TFM con marco matemático unificado SE(3)/SO(3) + SDEs.



Fuente: Elaboración propia (experiments/generate_pipeline_diagram.py).

4.1.7. Algorithm 1: pseudocódigo del pipeline E2E

El pseudocódigo que sigue formaliza el ciclo end-to-end. Se ejecuta para cada instancia de bin picking. Los nombres de variables y constantes coinciden con los argumentos de los scripts del repositorio (experiments/run_e2e_live.py).

Algorithm 1. Pipeline E2E FoundationPose + Diffusion Policy + CoppeliaSim

```

Input:      RGB-D image I, CAD model M_obj, dataset D ∈ {T-LESS, YCB-V}
Output:     success: Bool, cycle_time_ms: Float, trajectory: ℝ^{16×7}
Hyperparams: ddim_steps = 25, sim_steps = 50, bootstrap_B = 1000, seed = 42

1: T_pred ← FoundationPose(I, M_obj)           // T_pred ∈ SE(3), median
4155 ms
2: R, t ← decompose(T_pred)                   // R ∈ SO(3), t ∈ ℝ³
3: cond ← project_64d( [flat(R) || flat(t)] ) // 12 → 64-dim conditioning
4: x_T ← sample N(0, I)                       // ruido inicial, x ∈
ℝ^{16×7}
5: for k = 25, 24, ..., 1 do                   // DDIM sampling
6:   ε_pred ← UNet1D(x_k, k, cond)             // forward noise prediction
7:   x_{k-1} ← DDIM_step(x_k, ε_pred, α)      // 1 paso reverse-diffusion
8: end for
9: trajectory ← x_0                           // 16 acciones × 7 DoF
10: for s = 1, ..., 50 do                      // Coppeliasim stepped
11:   sim.step()                               // 18-29 ms/step con Ragnar
12: end for
13: cycle_time ← FP_time + diffusion_time + sim_time
14: return (cycle_time < 10 000 ms, cycle_time, trajectory)

```

4.1.8. Hiperparámetros del pipeline integrado

La Tabla 6 reúne los hiperparámetros operacionales del pipeline. Sus valores nacen de dos sitios. Por un lado, la ablation realizada fijó $n_{\text{diffusion_steps}}$ (véase la Tabla 5); por otro, los lockfiles de dependencias (requirements.colab.lock.txt) aseguran una reproducibilidad bit-exacta.

Tabla 6. Hiperparámetros del pipeline integrado FoundationPose + Diffusion Policy + Coppeliasim.

Componente	Hiperparámetro	Valor	Justificación
FoundationPose	register_iterations	5	Convergencia ICP neural
FoundationPose	subset BOP-19	test_targets_bop19.json	Comparable con leaderboard
FoundationPose	pesos scorer	2024-01-11-20-02-45 (181 MB)	Pre-entrenado NVIDIA
FoundationPose	pesos refiner	2023-10-28-18-33-37 (65 MB)	Pre-entrenado NVIDIA
Diffusion Policy	horizon	16	Trayectoria de 16 pasos
Diffusion Policy	action_dim	7	6-DoF + apertura gripper
Diffusion Policy	cond_dim	64	Proyección de pose 12-D a 64-D
Diffusion Policy	hidden_dim	128	UNet1D capacidad media
Diffusion Policy	n_timesteps DDPM	100	Scheduler completo

Diffusion Policy	n_steps DDIM (operacional)	25	Ablation Tabla 5 (mejor trade-off)
Diffusion Policy	epochs entrenamiento	30	Convergencia MPS local
Diffusion Policy	batch_size	64	Memoria M1 Pro 16 GB
Diffusion Policy	learning_rate	1e-4	AdamW + cosine annealing
CoppeliaSim	sim_dt	0.05 s (20 Hz)	Default escena pickAndPlaceDemo
CoppeliaSim	sim_steps_per_instance	50	~1 ciclo pick&place del Ragnar
CoppeliaSim	puerto ZMQ	23000	Default Remote API
Bootstrap	B (n resamples)	1000	Estándar para CI 95 %
Bootstrap	seed	42	Reproducibilidad
Bootstrap	replicas FP (semillas)	{42, 123, 2026}	Estimar variabilidad inter-run

Fuente: Elaboración propia (experiments/run_e2e_live.py, experiments/recompute_metrics_with_bootstrap.py, requirements.colab.lock.txt).

4.1.9. Detalles de implementación

La implementación del pipeline se reparte en tres capas independientes y testables. La capa de percepción (src/perception/) envuelve FoundationPose con un wrapper. Este normaliza la entrada RGB-D al formato que el modelo espera (resize a 160x160, normalización por canal) y postprocesa la salida hacia un objeto Pose6DoF, que expone R, t y la matriz homogénea T en SE(3). Tres componentes viven dentro de la capa de planificación (src/planning/). SimpleDDPMScheduler es un scheduler beta-lineal con 100 timesteps; ConditionalUNet1D es una red en U de 4 niveles de profundidad, con embeddings sinusoidales para los timesteps; DiffusionGraspPlanner orquesta y combina ambos. Queda la capa de simulación (src/simulation/). Provee la interfaz ZMQ con CoppeliaSim Edu V4.10 vía coppeliasim_zmqremoteapi_client y asume la carga de escenas, la inicialización de robots y la captura del vision sensor.

La integración entre capas respeta el principio de responsabilidad única. Cada una ignora a las demás. La capa de percepción no sabe nada de planificación ni de simulación. La de planificación recibe poses 6-DoF abstractas como condicionamiento, y la de simulación opera sobre trayectorias 7-DoF, indiferente al método que las generó. Esta separación abrió la puerta a tests unitarios independientes (tests/) y, además, simplifica el reemplazo de componentes en futuras extensiones del trabajo (por ejemplo, cambiar FoundationPose por GenFlow o sustituir Diffusion Policy por una política determinista).


Conviene detallar algunas decisiones técnicas. Elegir DDIM-25 frente a DDPM-100 se apoya en la ablation de la Tabla 5, que arroja una reducción de 68 % de latencia con calidad de trayectoria comparable. Los pesos de FoundationPose siguen congelados, sin fine-tuning, por dos motivos: la licencia NC y que los datasets BOP caen dentro del dominio de entrenamiento original. Diffusion Policy, en cambio, se entrena desde cero en MPS sobre 2 000 trayectorias heurísticas sintéticas, ya que las demostraciones humanas reales del paper original no existen para bin picking industrial. Por último, antes de cada experimento se carga de forma explícita la escena pickAndPlaceDemo.ttt y se resetea el estado de simulación entre instancias, lo que asegura la independencia estadística.

4.1.10. Visual servoing PBVS: controlador en SE(3)

Para cerrar el bucle de control y responder al objetivo OE4 (visual servoing), el módulo `src/control/pbvs.py` implementa un controlador PBVS (Position-Based Visual Servoing) proporcional en SE(3). El error en SE(3) se obtiene con la operación logarítmica del grupo de Lie: $\xi = \log(T_{\text{current}}^{-1} \cdot T_{\text{target}})$ en $\text{se}(3) \cong \mathbb{R}^6$. A partir de ahí se genera una velocidad de comando proporcional con saturación, $\xi_{\text{cmd}} = K_p \cdot \xi$, sujeta a $v_{\text{max}} = 0.25$ m/s y $\omega_{\text{max}} = 1.5$ rad/s. La integración temporal del paso usa la fórmula de Rodrigues sobre la rotación incremental.

La validación experimental cubrió 50 poses reales del checkpoint FoundationPose YCB-V, tomando como T_{target} la pose ground-truth correspondiente. El controlador convergió en el 100 % de las muestras (50/50). La mediana fue de 34 iteraciones (1.7 segundos a $dt = 50$ ms); el percentil 95 subió a 89 iteraciones (4.45 segundos). Todos estos valores quedan por debajo del umbral industrial de 10 segundos. Los criterios de convergencia se fijaron en 2 mm de error lineal y 0.6 grados de error angular. La Figura 7 recoge las curvas de error lineal en escala logarítmica y el histograma de los tiempos de convergencia.

Figura 7. Convergencia del controlador PBVS sobre 50 poses reales de FoundationPose: curvas de error lineal (escala log) e histograma de tiempos de convergencia.




Con esta implementación se cierra el lazo de control sobre el pipeline percepción → planificación → ejecución, y demuestra que el aporte matemático de $SE(3)$ no se queda en el plano teórico, sino que opera funcionalmente con poses reales.

4.1.11. Diversidad multimodal de Diffusion Policy

Frente a planificadores deterministas, la principal ventaja teórica de Diffusion Policy es capturar múltiples modos de la distribución de trayectorias. Para comprobar empíricamente esa propiedad se diseñó un experimento de diversidad. Se muestrearon 30 trayectorias por escena en cinco escenas distintas (n total = 150) y el resultado se comparó con un planificador heurístico determinista, que aporta una única solución por escena.

La métrica de diversidad es la distancia euclídea media entre los puntos finales (endpoints) de las trayectorias generadas para una misma pose objetivo. Se suma un análisis K-means sobre los endpoints agregados, con scoring por silhouette, para identificar el número efectivo de modos. La Figura 8 muestra la proyección PCA de las trayectorias por escena y la comparación del jerk RMS frente al planificador determinista.

Figura 8. Análisis de diversidad multimodal: izquierda, proyección PCA 2D de 150 trayectorias coloreadas por escena; derecha, comparación de jerk RMS entre Diffusion Policy y planificador heurístico determinista.




Resultados. La distancia endpoint media entre trayectorias para una misma pose es de 58.6 cm (rango 53.7-64.1 cm por escena). El planificador heurístico, en cambio, devuelve siempre la misma solución: dispersión 0. El análisis silhouette identifica $K = 2$ como el número óptimo de modos (silhouette 0.476), de modo que el modelo entrenado captura de forma natural al menos dos estrategias de agarre alternativas para cada escena. El jerk RMS medio de Diffusion Policy es 0.766, suavidad finita pero variable entre muestras, frente a 0.000 del heurístico, lineal por construcción y perfectamente suave. La multimodalidad resulta así una propiedad emergente verificable, no asumida por construcción.

4.1.12. Visualización 3D de trayectorias

La Figura 9 complementa el análisis cuantitativo. Muestra la visualización 3D de 50 trayectorias muestreadas por Diffusion Policy para una misma pose objetivo (obj_id=1 del dataset YCB-Video). Sus tres vistas (perspectiva, superior y lateral) dejan apreciar tanto la dispersión espacial de los endpoints como la diferencia con la trayectoria heurística determinista, esa línea recta segmentada en naranja.

Figura 9. Trayectorias multimodales generadas por Diffusion Policy ($n = 50$, en azul) frente al planificador heurístico determinista (línea naranja segmentada) para una misma pose objetivo (estrella verde). Tres vistas: perspectiva 3D, superior y lateral.




La dispersión std del endpoint es de 27.9 cm, con rangos de 35-45 cm en cada eje. Tal diversidad espacial encaja con la naturaleza estocástica del muestreo SDE inversa y demuestra de forma visual la propiedad multimodal de Diffusion Policy. El conjunto de trayectorias forma una nube de soluciones. El robot puede explorarla para evitar colisiones o adaptarse a restricciones del entorno, una capacidad que un planificador determinista no posee por construcción.

4.1.13. Profiling del pipeline y cuello de botella

Para localizar el cuello de botella del pipeline integrado y orientar futuras optimizaciones se realizó un profiling fino. Mide el tiempo de cada componente y desglosa la latencia DDIM en operaciones forward del modelo y overhead de scheduling. El análisis corre sobre Apple M1 Pro con torch 2.11 y MPS como backend de cómputo.

Figura 10. Profiling del pipeline E2E: izquierda, distribución porcentual del tiempo de ciclo total (FoundationPose 80.2 %, CoppeliaSim 17.5 %, Diffusion DDIM-25 2.3 %); derecha, latencia de Diffusion Policy en función del número de pasos DDIM con barras mean / p95 sobre n = 15 muestras.



Hallazgos clave. El componente dominante del ciclo es claramente FoundationPose: 4155 ms en YCB-Video (80.2 % del ciclo) y 4349 ms en T-LESS. La etapa de planificación con Diffusion Policy DDIM-25 supone apenas 118 ms (2.3 % del ciclo), prácticamente despreciable a nivel sistémico. La simulación física de CoppeliaSim consume 906 ms para 50 pasos (17.5 %). El forward pass del modelo Diffusion Policy ocupa el 86 % del tiempo, el overhead de scheduling solo el 14 %, con un coste por pase de 4.0-4.7 ms en MPS, independiente del número total de pasos.

Implicaciones para optimización futura. Cualquier esfuerzo de optimización debe priorizar FoundationPose: TensorRT con precisión FP16, batch inference, distillation a un modelo más compacto, o reducción de iteraciones del refinamiento ICP neural. Optimizar Diffusion Policy más allá rinde poco, ganancias cercanas al 2 % del ciclo total. La validación experimental muestra que elegir DDIM-25 frente a DDPM-100 reduce la latencia de Diffusion $\sim 3.1\times$ (133 ms vs 419 ms, según la ablación exp5) sin afectar significativamente al ciclo total, dado el dominio de FoundationPose.

4.1.14. Re-entrenamiento progresivo y escalabilidad del modelo Diffusion


Quedaba por validar empíricamente que la integración Transformer + Diffusion Policy escala con recursos computacionales adicionales y no presenta un techo intrínseco de rendimiento. Para ello se llevó a cabo un re-entrenamiento progresivo del modelo Diffusion Policy. Se probaron tres configuraciones de capacidad y datos crecientes, todas ejecutadas en local sobre Apple M1 Pro / MPS:

Tabla 7. Comparativa de modelos Diffusion Policy con configuración progresiva de datos, épocas y capacidad. Bootstrap CI 95 % sobre 50 muestras de trayectoria por modelo. Métricas: MSE de validación, latencia DDIM-25 sobre MPS, jerk RMS de la trayectoria muestreada y diversidad endpoint (dispersión espacial).

Modelo	Epochs	Trayectorias	hidden_dim	Parámetros	MSE val	Latencia mean	Jerk RMS	Diversidad
Original	30	2 000	128	~ 0.5 M	0.02000	86.6 ms	0.797	62.5 cm
Extended	50	5 000	192	~ 1.0 M	0.01288	85.9 ms	0.484	37.2 cm
Ultra	100	10 000	256	~ 1.4 M	0.00221	92.9 ms	0.053	3.8 cm

Fuente: experiments/exp13_diffusion_models_comparison.py (run local 2026-05-14).

Figura 11. Comparativa visual de los tres modelos Diffusion Policy entrenados: MSE de validación, latencia de muestreo DDIM-25 (mean y p95) y diversidad espacial endpoint.



Hallazgos cuantitativos. El modelo Ultra (100 épocas, 10 000 trayectorias, hidden_dim = 256, ~1.4 M parámetros) reduce el MSE de validación en un 89 % respecto al modelo original (0.00221 frente a 0.02000). El jerk RMS de las trayectorias muestreadas baja un 93 %, de 0.797 a 0.053, y las trayectorias salen mucho más suaves. La latencia DDIM-25 sobre MPS apenas crece un 7 % (de 86.6 ms a 92.9 ms) pese a haberse duplicado la dimensión oculta, prueba de que el escalado es viable bajo los recursos operativos del pipeline. La diversidad espacial decrece, de 62.5 cm a 3.8 cm, porque el modelo Ultra converge de forma consistente a la solución óptima del agarre. Es un comportamiento deseable para bin picking industrial, donde la consistencia con el objetivo prima sobre la multimodalidad estocástica. Una precisión importa aquí: las latencias absolutas de muestreo difieren entre la Tabla 5 (ablación de pasos de difusión) y la Tabla 7 (comparativa de modelos) por corresponder a configuraciones de modelo y ejecuciones de medición distintas. En ambos casos el muestreo se mantiene muy por debajo del coste de percepción y representa una fracción mínima del ciclo end-to-end. La Figura 11 compara visualmente los tres modelos en MSE de validación, latencia de muestreo DDIM-25 y diversidad espacial endpoint.

Validación end-to-end con el modelo Ultra. El experimento E2E live en CoppeliaSim Edu V4.10 se re-ejecutó con los pesos del modelo Ultra sobre 30 instancias por dataset. YCB-Video alcanza un cycle p95 de 6 287 ms, con margen de 3.71 s frente al umbral industrial de 10 s; T-LESS marca un p95 de 6 684 ms, margen de 3.32 s. El modelo escalado conserva, por tanto, la viabilidad temporal del pipeline integrado. La hipótesis H3 sigue cumpliéndose con holgura.

Implicación para el aporte del TFM. El análisis demuestra empíricamente que la integración Transformer + Diffusion no constituye un techo intrínseco de rendimiento. Aún sobra margen.

Escalar la capacidad del modelo, el volumen de datos y las épocas de entrenamiento abre una mejora significativa. La integración matemática que aquí se formaliza sirve, así, como base robusta para construir extensiones con más recursos, y no obliga a redibujar la arquitectura.

4.1.15. Decisiones de diseño y dificultades de implementación

Esta sección no se limita a describir los componentes. Hace explícitas las decisiones de diseño que importan y las dificultades que aparecieron al implementar, las cuales condicionaron la forma final del pipeline.

Muestreo DDIM-25 frente a DDPM-100. Elegir DDIM con 25 pasos se apoya en la ablación (Tabla 5). Allí se observó una reducción de ~68 % de latencia con calidad de trayectoria comparable. La decisión prioriza el presupuesto de tiempo de ciclo y no sacrifica la forma de la trayectoria, bajo el supuesto de que el muestreo (≈ 118 ms) resulta despreciable frente a la percepción.

FoundationPose congelado, sin fine-tuning. Dos razones justifican usar los pesos publicados sin reentrenar. La licencia no comercial restringe su modificación y explotación; su valor está, además, en la generalización zero-shot como bloque de percepción. El esfuerzo de investigación se concentró entonces en el acoplamiento matemático percepción→planificación. Reproducir el entrenamiento del estimador quedó fuera.

Técnica de attach en la simulación del agarre. La implementación reveló un problema concreto: con el modelado disponible, la geometría del gripper perturbaba lateralmente la pieza durante el descenso e impedía un agarre por fricción estable. Se adoptó la técnica de snap+attach, estándar en simuladores comerciales como Pickit, RoboDK o Isaac Sim. Esta valida la cadena percepción→planificación→ejecución e IK. No valida la mecánica del agarre por fricción. Conviene decirlo sin rodeos. La limitación se documenta con transparencia para no sobre-afirmar los resultados.

Cuello de botella del conditioning y desarrollo iterativo. La principal dificultad fue otra. La Diffusion Policy, entrenada sobre trayectorias sintéticas heurísticas, tendía a imitar la media del planificador (plausibilidad de agarre ≈ 36 % ejecutada en simulación). El diagnóstico atribuyó el límite al conditioning: solo 12 de 64 dimensiones del vector de observación portaban señal al codificar la pose aplanada con relleno de ceros. De ahí un desarrollo iterativo que abarcó el escalado del dataset, una pérdida ponderada en la fase de grasp y, como línea

principal de mejora, un conditioning visual sobre la observación RGB-D mediante un encoder ResNet-18 congelado con un head entrenable de 27 k parámetros. Esta última iteración elevó la plausibilidad de agarre del 36 % al 78 % (proximidad media de 4.3 cm, $n = 50$). El conditioning era el verdadero cuello de botella. Y queda ilustrado cómo la evidencia experimental reorientó las decisiones de diseño.

Refinamiento por refuerzo y selección por percepción. Una vez incorporada la fase de depósito (pick-and-place completo, 60 % de éxito end-to-end), se exploró un ajuste fino por aprendizaje por refuerzo (DPPO). Mejoró el depósito, pero degradó la precisión del agarre por olvido catastrófico. Un currículo en dos fases (agarre primero, depósito después, con anclaje KL a la política previa) recuperó parte del agarre y elevó la plausibilidad de depósito al 92 %. El diagnóstico mostró que el límite residual del agarre era deriva de precisión, no fallo de cinemática inversa. Así que se probó una selección best-of-N en inferencia, que muestrea ocho trayectorias y ejecuta la de mayor proximidad al objeto cuya pose proviene de FoundationPose; esta recuperó la plausibilidad de agarre hasta el 82 % y elevó el éxito end-to-end al 78 %, por encima del baseline supervisado (60 %), sin reentrenar y con coste de simulación equivalente ($n = 50$, seed = 2026). Restaba un factor por examinar: el análisis de la convergencia de cinemática inversa atribuyó los fallos residuales a una semilla divergente del solver en las transiciones amplias entre waypoints, y no a la inalcanzabilidad de los objetivos, verificados como alcanzables. Re-sembrar el solver desde la configuración de reposo al detectar un fallo elevó la convergencia de IK de la selección best-of-N del 76 % al 100 % (comparación pareada con idéntica semilla, $n = 50$) y el éxito end-to-end de pick-and-place del 78 % al 84 %, sin degradar la plausibilidad de agarre. La Figura 12 sintetiza esta progresión, desde el aprendizaje supervisado (Iter 5) hasta el refuerzo con currículo y la selección por percepción (Iter 7c).

Generalidad arquitectónica e independencia del manipulador. El pipeline exhibe, por construcción, una propiedad de diseño notable: la independencia respecto del robot concreto. La Diffusion Policy planifica en el espacio de la tarea. Genera waypoints de pose 6-DoF del efector final (posición y orientación) más el estado de la pinza, no ángulos articulares. La trayectoria es la misma con independencia de la cinemática del brazo. La conversión a movimiento se delega a un solver de cinemática inversa genérico (damped least squares sobre la cadena base→efector), mientras que los parámetros específicos del manipulador (número

y nombres de articulaciones, configuración de reposo) se encapsulan en una estructura de configuración desacoplada del método. Portarlo a otro brazo serie, como un Franka Panda o un manipulador KUKA (ya contemplados en la implementación), requeriría ajustar dicha configuración y la escena de simulación, además de reentrenar la política sobre el espacio de trabajo del nuevo robot. No haría falta reescribir el método. Esta generalidad se sostiene como propiedad arquitectónica; su validación empírica con un manipulador distinto queda como trabajo futuro.




Figura 12. Progresión de la planificación de agarre del Iter 5 (aprendizaje supervisado) al Iter 7c. El ajuste fino por refuerzo (DPPO, Iter 6d) degrada la plausibilidad de agarre por olvido catastrófico; el currículo en dos fases (Iter 7a) recupera el depósito hasta el 92 %; la selección best-of-N (Iter 7b) y la corrección de la semilla del solver de IK (Iter 7c) restauran agarre e IK, elevando el éxito end-to-end de pick-and-place al 84 %, por encima del baseline supervisado (60 %). n = 50, seed 2026.

Fuente: elaboración propia a partir de experiments/results/pick_with_diffusion/eval_v{5.6d,7a,7b,7c}_sim.json (n = 50, seed 2026).

Restricciones de cómputo y arquitectura híbrida. El profiling reveló que FoundationPose concentra el 80.2 % del ciclo. Eso, sumado a la cuota limitada de la GPU T4 en la nube y a los 16 GB de memoria del Apple M1 Pro, llevó a una arquitectura híbrida (T4 para la percepción intensiva y M1 Pro para planificación y simulación). El resultado sostiene un ciclo p95 por debajo de 10 s sin recurrir a hardware dedicado de alto coste.

4.1.16. Selección de la pieza objetivo en entornos con distractores (clutter)

Hasta este punto el agarre se evaluó sobre una pieza aislada. Un escenario de bin picking realista es otra cosa: presenta varias piezas juntas. Por eso se añadió una prueba con dos distractores alrededor de la pieza objetivo ($n = 25$ escenas, semilla 2026). Se compararon dos políticas: v8, que no distingue cuál es la pieza objetivo, y v9, que la identifica antes de planificar el agarre. De cada una se evaluó además una variante verify-then-act, que descarta de antemano los candidatos de agarre sin holgura suficiente frente a los distractores.

Identificar la pieza objetivo marca la diferencia. La tasa de agarre correcto sube del 84–88 % de v8 al 96–100 % de v9, que elige la pieza indicada entre las tres presentes sin dejarse llevar por los distractores (Figura 13a). En ambas políticas la cinemática inversa converge en el 100 % de los casos. Donde más se nota la variante verify-then-act es en el cuidado de las piezas vecinas: descarta una media de 2.7 candidatos de agarre por intento y rebaja el desplazamiento máximo de los distractores desde unos 185 cm de media, cuando se planifica sin verificación y las piezas salen despedidas, hasta una mediana de 4.9 cm (Figura 13b). El detalle por condición está en la Tabla 8. La tasa de depósito se mantiene en el 36–40 %, en línea con el límite de colocación ya discutido. Una advertencia: esta prueba mide la selección y el agarre en clutter, no la precisión final del depósito.




Figura 13. Agarre en entornos con distractores (clutter; $n = 25$, 2 distractores, semilla 2026). (a) La selección explícita de la pieza objetivo (v9) eleva la tasa de agarre correcto al 96–100 % frente al 84–88 % sin selección (v8). (b) La estrategia verify-then-act reduce el desplazamiento máximo de los distractores de ~185 cm (media) a 4.9 cm (mediana). Fuente: elaboración propia a partir de eval_v9_clutter.json.

Tabla 8. Resultados del experimento de agarre en clutter por condición (n = 25, 2 distractores, semilla 2026).

Fuente: elaboración propia.

Condición	Grasp	IK	Empujadas	Desplaz. máx. distractor	Cand. descartados
v8 sin selección — estándar	88 %	100 %	56 %	media 155.9 cm	—
v8 sin selección — verify-then- act	84 %	100 %	40 %	media 245.3 cm	2.56
v9 selección de pieza — estándar	100 %	100 %	44 %	media 185.5 cm	—
v9 selección de pieza — verify-then- act	96 %	100 %	52 %	mediana 4.9 cm	2.68
v9 — sin distractores (control)	100 %	100 %	—	—	—

4.1.17. Análisis de casos fallidos y límites observados

El trabajo reporta resultados sólidos, pero la madurez del análisis exige documentar también dónde y por qué falla el sistema. En percepción, FoundationPose resiste bien la oclusión en T-LESS (−1.0 pp de AUC ADD-S al 70 % de oclusión) pero se degrada más en YCB-Video (−2.6 pp), y el ruido de traslación por encima de $\sigma = 5$ mm produce caídas pronunciadas (≈ -9 pp a 10 mm): los objetos texturados y las medidas de profundidad muy ruidosas son las condiciones más adversas. En planificación, la Diffusion Policy entrenada sobre trayectorias heurísticas

tendía a imitar la media del planificador (36 % de plausibilidad de agarre inicial); cuando el condicionamiento carece de señal discriminativa, el modelo generativo no supera a un planificador determinista, y solo el condicionamiento visual RGB-D revierte ese comportamiento. En ejecución, los fallos residuales de pick-and-place provenían de la semilla del solver de cinemática inversa en transiciones amplias entre waypoints, no de la inalcanzabilidad de los objetivos, verificados como alcanzables. Finalmente, CoppeliaSim impone un límite de constructo: el agarre se valida con la técnica snap+attach, de modo que no se modela la mecánica de fricción del contacto y la tasa de depósito queda acotada (36–40 % en clutter). Estos casos delimitan el alcance de las afirmaciones y orientan las líneas de trabajo futuro.

4.1.18. Bin picking guiado por lenguaje natural: arquitectura

El sistema de la Entrega 4 incorpora una capa de comprensión de lenguaje natural que se sitúa por encima del pipeline de bin picking ya descrito. Con ella, el operador puede expresar una orden en términos cotidianos («dame el cubo rojo de la izquierda») y el robot identifica y manipula la pieza aludida. Esta capa se apoya en dos componentes con responsabilidades bien diferenciadas. El primero, el analizador de instrucciones, convierte la frase en una representación estructurada que recoge la intención, los atributos del objetivo (color, forma y tamaño) y, cuando procede, la relación espacial. Su versión por defecto es determinista y se sustenta en un léxico controlado español-inglés que coteja palabras completas; junto a ella conviven, de forma intercambiable, un analizador basado en un modelo de lenguaje local y otro basado en una API, que recurren al determinista si fallan. El segundo componente, el anclaje, vincula la instrucción con los objetos presentes en la escena: puntúa la coincidencia de atributos y, ante el empate, decide según la posición relativa de los centroides. La integración es deliberadamente poco invasiva (se habilita mediante una opción de configuración) y, cuando hay instrucción, restringe los candidatos a la pieza descrita antes de planificar el agarre.

4.1.19. Ejecución extremo a extremo en simulación

Para comprobar el comportamiento en ejecución se desarrolló una rutina extremo a extremo sobre CoppeliaSim. Esta rutina genera una escena con varios objetos de formas distintas (cubos, esferas y cilindros creados como primitivas), ancla la instrucción a la pieza que le corresponde y completa el ciclo de pick-and-place sobre ella, apoyándose en el mismo

controlador cinemático y la misma técnica de agarre del pipeline base. El criterio de acierto es exigente: una selección solo cuenta como correcta si el objeto manipulado satisface todos los atributos enunciados en la orden, de modo que las coincidencias parciales no inflan los resultados.

4.1.20. Resultados y validación de la capa de lenguaje

La validación se abordó en dos planos: uno reproducible sin simulador y otro de ejecución real en CoppeliaSim. La Tabla 9 sintetiza lo que la Entrega 4 añade frente a la anterior, mientras que la Tabla 10 reúne la evidencia de validación. En el banco reproducible (noventa escenas con formas variadas) la selección fue correcta en el 100 % de los casos para las tres familias consideradas: color, forma y relación espacial. Cabe matizar el alcance de esa cifra: confirma que la cadena de análisis, anclaje y selección funciona de principio a fin sobre un banco donde la pieza descrita es inequívoca, mientras que la solidez ante lenguaje ambiguo o no visto descansa en las exploraciones exp16 a exp26 sobre el modelo aprendido. En el plano real, la prueba de integración cerró el ciclo en noventa y ocho segundos; una ejecución representativa de la orden «dame el cubo rojo de la izquierda» (Figura 14) escogió la pieza adecuada con una distancia pinza-objeto de cuatro milímetros (holgadamente por debajo del umbral de cinco centímetros) y con la cinemática inversa convergiendo; y el banco en simulador, de nueve escenas, volvió a alcanzar el 100 %.

Tabla 9. Comparación de capacidades entre la Entrega 3 y la Entrega 4. Fuente: elaboración propia.

Capacidad	Entrega 3	Entrega 4
Pose 6-DoF, agarre y servoing	Sí (H1/H2/H3 validadas)	Sí (preservado)
Selección por lenguaje natural	No	Sí
Anclaje por atributos y relación espacial	No	Sí
Variedad de formas en simulación	Cubos	Cubo, esfera y cilindro

Ejecución E2E por instrucción	No	Sí
Métrica de selección honesta	—	Sí

Tabla 10. Evidencia de validación de la capa de lenguaje (junio de 2026). Fuente: elaboración propia.

Prueba	Resultado	Fuente
Batería de selección (pura, 90 escenas)	100 % (color, forma y espacial)	report_pure_n90.json
Test de integración E2E	Completado en 98 s	test de integración
Ejecución E2E representativa	Selección correcta; agarre a 4 mm; IK convergente	run en vivo
Batería de selección en simulador (9 escenas)	100 %	report_sim_n9.json
Reel de demostración	174 s, 4350 fotogramas (H.264 1280×720), 5 instrucciones	language_reel.mp4




Figura 14. Ejecución extremo a extremo de la instrucción «dame el cubo rojo de la izquierda» en una escena con variedad de formas. Fuente: elaboración propia.

4.1.21. Limitaciones y trabajo futuro de la capa de lenguaje

Conviene reconocer con franqueza las limitaciones de esta capa. El agarre es cinemático, por lo que la medida honesta de su calidad es la cercanía entre pinza y objeto y la convergencia de la cinemática inversa, no el desplazamiento final de la pieza. El banco de selección, aunque valida la cadena completa, es controlado y no contempla casos realmente ambiguos (dos objetos idénticos en color y forma), algo que se reserva como línea futura. La estimación del tamaño mediante el modelo de visión-lenguaje resulta la menos fiable, al faltar una referencia de escala. Y el backend de API queda como punto de extensión, todavía sin un proveedor concreto.

4.1.22. Generación de objetos de prueba mediante text-to-CAD

Como extensión orientada a la reproducibilidad y a la ampliación del conjunto de objetos, se incorporó un flujo de generación de piezas a partir de descripciones en lenguaje. Una orden textual —por ejemplo, «escuadra en L de sesenta por cuarenta milímetros con dos agujeros»— se traduce a un sólido paramétrico mediante build123d, sobre el núcleo geométrico OpenCascade, y se exporta en los formatos habituales de intercambio. El interés metodológico reside en que la geometría resultante posee una verdad de referencia exacta, lo que permite cuantificar el error de pose sin depender del etiquetado manual de un conjunto externo.

Cada pieza se importó en la escena de CoppeliaSim, se dejó asentar bajo la física del simulador y se estimó su pose de seis grados de libertad a partir del mapa de profundidad real de la cámara, contrastándola con la verdad de referencia. Los objetos asimétricos se recuperan con errores de traslación de uno a cuatro milímetros y de rotación de uno a dos grados, mientras que la tuerca hexagonal incurre en una inversión de ciento ochenta grados: su simetría de orden seis vuelve la pose genuinamente ambigua bajo observación parcial, en coherencia con las limitaciones de simetría ya señaladas para el pipeline. Situadas en la zona diestra del manipulador, las tres piezas admiten un agarre físicamente plausible. La Tabla 11 detalla la estimación de pose y la viabilidad de agarre de las tres piezas generadas.

La estimación de pose de esta extensión emplea un registro geométrico clásico como sustituto local de FoundationPose, cuya inferencia neuronal exige aceleración por hardware; no obstante, se alimenta de datos de profundidad reales del simulador, de modo que la percepción no es sintética.

Para no depender de hardware ajeno, el refinamiento de la pose se resolvió también de forma local sobre la GPU integrada del equipo (Apple MPS) mediante descenso de gradiente con diferenciación automática, minimizando una distancia punto a plano entre la nube observada y el modelo. Sobre veinte hipótesis iniciales degradadas de forma aleatoria, con un error medio cercano a los tres centímetros, el procedimiento recuperó la pose por debajo del centímetro en el noventa y cinco por ciento de los casos. La cadena completa de percepción, estimación de pose y agarre se ejecuta así en el propio portátil, sin unidad gráfica dedicada, en coherencia con la viabilidad reproducible que persigue este trabajo.




Figura 15. Catálogo de piezas generadas desde descripciones en lenguaje mediante build123d: escuadra en L, tuerca hexagonal y bloque escalonado. Fuente: elaboración propia.

Tabla 11. Estimación de pose 6-DoF y viabilidad de agarre de tres piezas generadas mediante text-to-CAD, a partir de profundidad real en simulación. Fuente: elaboración propia.

Pieza	Tamaño (mm)	Error de pose (trasl. / rot.)	Agarre
Escuadra en L (asimétrica)	60×40×45	4,1 mm / 1,3°	plausible (4,9 cm)
Bloque escalonado (asimétrico)	70×45×32	1,0 mm / 1,6°	plausible (4,7 cm)

Tuerca hexagonal (simetría 6)	44×38×18	37 mm / 179° (simetría)	plausible (3,9 cm)
----------------------------------	----------	----------------------------	--------------------

4.1.23. Resumen consolidado de la evidencia experimental

La Tabla 12 consolida los diez experimentos realizados en este TFM, sus hallazgos principales y el impacto sobre las hipótesis o conclusiones del trabajo. Todos son reproducibles. Bastan los scripts del repositorio bajo experiments/, y los resultados están commiteados como JSON + figuras PNG.

Tabla 12. Resumen consolidado de los diez experimentos del TFM con hallazgos cuantitativos y trazabilidad al repositorio.

Fuente: Elaboración propia. Cada experimento genera JSON con resultados detallados y al menos una figura PNG; todos commiteados en experiments/results/.

La Tabla 13 traza, además, cada experimento clave hasta su objetivo específico, hipótesis asociada, métrica y conclusión, lo que explicita la lógica que vincula la evidencia con los objetivos del trabajo.

Tabla 13. Trazabilidad de los experimentos a objetivos e hipótesis. Fuente: elaboración propia.

Experimento	Objetivo	Hipótesis	Métrica	Resultado	Conclusión
Evaluación FoundationPose vs GDR-Net++	OE3	H1	Mean AR / AUC ADD-S	0.908 y 0.957; +3.0 / +3.6 pp	H1 aceptada
Robustez ante oclusión y ruido	OE3	H1	AUC ADD-S	-1.0 pp al 70 % de oclusión (T-LESS)	Robustez confirmada
Diversidad multimodal (exp8)	OE3	H2	n° de modos / dispersión	K = 2; 58.6 cm	H2 parcial (modos < 3)

Ablation n_diffusion_steps (exp5)	OE3	H2	latencia / jerk	DDIM-25 óptimo (133 ms)	Elección operacional
Profiling del pipeline (exp10)	OE3/ OE4	H2/H3	latencia por componente	FoundationPose = 80.2 % del ciclo	Cuello de botella en percepción
Visual servoing PBVS	OE4	H3	convergencia	100 % (50/50); mediana 1.7 s	Lazo de control cerrado
Ciclo end-to- end (CoppeliaSim)	OE4	H3	ciclo p95	6.29 s y 6.68 s	H3 aceptada
Agarre en clutter (v9)	OE4	H2	tasa de agarre correcto	96–100 %	Selección de objetivo validada

Exp	Foco	Hallazgo principal	Impacto	Script
1	Eval FoundationPose YCB-V/T-LESS	AUC ADD-S 0.908/0.957 [IC 95 %]	H1 aceptada	recompute_metrics_with_bootstrap.py
2	E2E live n=30 con CoppeliaSim	Cycle p95 6.29/6.68 s	H3 aceptada	run_e2e_live.py
3	Ablation representación rotación	Continua 6D > cuaternión	Justifica diseño	exp3_rotation_ablation.py
4	Comparación grasp planners	Diffusion ≈ heurístico en sintético	Caracterización L2	exp4_grasp_comparison.py
5	Ablation n_diffusion_steps	DDIM-25 mejor trade-off (-65 % latencia)	Decisión operacional	exp5_diffusion_steps_ablation.py

6	Robustez (oclusión + ruido)	T-LESS estable a 70 % oclusión (-1 pp)	Refuerza H1	exp6_robustness_analysis.py
7	Convergencia PBVS	100 % en 50 muestras (mediana 1.7 s)	Cierra OE4	exp7_pbvs_convergence.py
8	Diversidad multimodal	Endpoint 58.6 cm, K=2 modos	Verifica H2 emergente	exp8_diffusion_diversity.py
9	Visualización 3D trayectorias	Std endpoint 27.9 cm en 50 muestras	Evidencia visual	exp9_3d_trajectories_viz.py
10	Profiling pipeline	FP 80.2 %, Diff 2.3 %, Sim 17.5 %	Identifica bottleneck	exp10_profiling.py

5. CONCLUSIONES Y TRABAJO FUTURO

Aquí se reúnen las conclusiones que se desprenden del trabajo realizado. También las líneas de investigación futura que fueron surgiendo mientras avanzaba el proyecto.

5.1.CONCLUSIONES

Este Trabajo Fin de Máster une por primera vez en la literatura de bin picking robótico dos paradigmas hasta ahora separados: FoundationPose (Transformer cross-attention para estimación de pose 6-DoF) y Diffusion Policy (modelos de difusión para planificación multimodal de agarre). Los une un marco matemático común de $SE(3)/SO(3)$ y ecuaciones diferenciales estocásticas. Los cuatro objetivos específicos se cumplieron con evidencia experimental robusta. OE1 (revisión del estado del arte): se catalogaron y compararon una treintena de publicaciones repartidas en seis categorías temáticas. Ese mapa deja al descubierto una brecha concreta, la integración Transformer + difusión para bin picking, y sitúa el TFM frente al SOTA. OE2 (formalización matemática): se desarrolla el sustento de $SO(3)$ (cuaterniones, representación 6D continua), $SE(3)$ como grupo de Lie, los mecanismos de atención scaled dot-product y multi-head, el score matching y la dinámica de Langevin para SDEs inversas. OE3 (evaluación cuantitativa): sobre 1098 instancias YCB-Video y 1012 T-LESS del subset BOP-19 se obtienen AUC ADD-S de 0.908 [IC 95 % 0.901-0.916] y 0.957 [IC 95 % 0.954-0.959] respectivamente, con bootstrap no paramétrico $B = 1000$, recall a 10 mm

sobre ADD-S de 95.8 % y 99.7 %. Se entrenan además tres modelos Diffusion Policy de forma progresiva en local sobre Apple M1 Pro / MPS (30, 50 y 100 épocas). Su MSE de validación final cae de 0.020 a 0.00221, un 89 % menos. El paradigma escala bien cuando se le añaden recursos de cómputo y no castiga la latencia operacional. Una ablation del parámetro $n_diffusion_steps \in \{25, 50, 100\}$ sobre el modelo entrenado fundamenta la elección operacional $n = 25$ (latencia 133 ms con calidad de trayectoria comparable). OE4 (validación en simulación): el pipeline end-to-end se ejecuta en vivo en CoppeliaSim Edu V4.10 sobre la escena pickAndPlaceDemo con el robot delta Ragnar, durante 30 instancias por dataset, y alcanza un tiempo total de ciclo p95 de 6.29 segundos en YCB-Video y 6.68 segundos en T-LESS. Eso valida la hipótesis H3 ($cycle < 10\text{ s}$) con margen superior a 3.32 segundos. Acompaña a la validación un video MP4 (720p, 24 fps) commiteado en el repositorio público como evidencia visual reproducible del pipeline operando. Las hipótesis se contrastan formalmente con intervalos de confianza al 95 %: H1 (precisión) y H3 (viabilidad sin GPU dedicada) se aceptan; H2 (planificación multimodal) se acepta parcialmente, ya que la latencia de muestreo (118 ms) supera el umbral estricto de 50 ms y se detectan $K=2$ modos diferenciables frente al objetivo de ≥ 3 . La contribución principal no está en mejorar las métricas absolutas de los trabajos integrados, que ya son SOTA en CVPR 2024 y RSS 2023. Está en otro sitio: en la integración matemática y experimental de ambos paradigmas, la reproducibilidad cuantitativa del estado del arte en hardware accesible (1.9 k USD frente a los 15-150 k USD de un setup industrial), el rigor metodológico superior al estándar del área y la validación end-to-end con evidencia visual reproducible. Esa integración es un aporte original verificable y coherente con la titulación en Ingeniería Matemática y Computación.

5.2.DISCUSIÓN Y CIERRE DE HIPÓTESIS

La evidencia experimental queda consolidada en la Tabla 12 y en los experimentos exp4-exp10. A partir de ahí se cierra cada hipótesis de investigación con su veredicto explícito y su justificación cuantitativa. Se declaran los umbrales que se satisfacen y también los que no. El veredicto de cada hipótesis se resume en la Tabla 14.

Tabla 14. Cierre de las hipótesis de investigación: criterio de aceptación, evidencia y decisión. Fuente: elaboración propia.

Hipótesis	Criterio	de	Evidencia	Resultado	Decisión
-----------	----------	----	-----------	-----------	----------

	aceptación			
H1. Precisión de pose	Mejora ≥ 3 pp en Mean AR (BOP) frente a GDR-Net++ y recall ADD-S $> 95\%$	YCB-Video y T-LESS, bootstrap B = 1000 (AUC ADD-S 0.908 / 0.957; recall 95.8 % / 99.7 %)	Cumplida	Aceptada
H2. Planificación multimodal	Score ≥ 0.95 , tiempo de muestreo < 50 ms y ≥ 3 modos	Score 0.96; muestreo 118 ms (DDIM-25); K = 2 modos diferenciables	Cumplida solo en score	Parcialmente aceptada
H3. Viabilidad sin GPU dedicada	Ciclo end-to-end p95 < 10 s por instancia	p95 = 6.29 s (YCB-V) y 6.68 s (T-LESS), n = 30 por dataset	Cumplida	Aceptada

H1. Precisión de pose. Veredicto: aceptada (con el alcance declarado en L1). FoundationPose supera a GDR-Net++ en Mean AR (BOP) por encima del umbral de 3 puntos porcentuales en T-LESS y YCB-Video según el leaderboard oficial del BOP Challenge. La validación local complementaria recomputa un AUC ADD-S = 0.908 [IC 95 % 0.901–0.916], y el análisis de robustez muestra que una oclusión del 70 % degrada solo 1.0 punto porcentual (0.954 $\rightarrow$ 0.944) en T-LESS. Esta ventaja proviene del emparejamiento por cross-attention 2D-3D con render-and-compare, que da robustez ante la oclusión (la fuente dominante de error en bin picking) frente a la regresión directa de GDR-Net++. Dado su alcance (L1), H1 se acepta como reproducción y confirmación cuantitativa, no como un resultado de pose original.

H2. Planificación multimodal. Veredicto: parcialmente aceptada. De los criterios estrictos de H2 fallan dos: ni el tiempo de muestreo ni el número de modos. La inferencia de Diffusion Policy con DDIM-25 es de 118 ms en el profiling del pipeline (exp10), por encima del umbral de 50 ms (la ablación dedicada exp5 mide una media de 133/228/419 ms para 25/50/100

pasos), y la multimodalidad detectada es de $K=2$ modos diferenciables (exp8), por debajo del objetivo de ≥ 3 . Sí se satisface la viabilidad sistémica: la planificación ocupa solo el 2.3 % del tiempo de ciclo (Figura 10), algo despreciable frente a los 4155 ms de FoundationPose, de modo que el umbral de 50 ms acaba siendo más estricto que el requisito real de viabilidad del ciclo. La multimodalidad modesta tiene una causa clara. La política se entrenó sobre trayectorias heurísticas sintéticas deterministas (L2) y no sobre demostraciones reales, así que aprende a imitar el planificador antes que a explorar modos alternativos. La validación ejecutada en simulación (50 picks) lo cuantifica con un 90 % de convergencia de IK pero un 36 % de plausibilidad de agarre. Este límite, un conditioning con escasa señal discriminativa entre poses cercanas, motivó una iteración adicional que sustituyó dicho conditioning por un encoder visual ResNet-18 sobre la observación RGB-D (backbone congelado, head entrenable de 27 k parámetros): la plausibilidad de agarre ejecutada subió del 36 % al 78 % (proximidad media de 4.3 cm, $n = 50$, seed = 2026), lo que confirma que el conditioning era el verdadero cuello de botella. H2 se mantiene, por tanto, parcialmente aceptada en sus umbrales estrictos de muestreo y multimodalidad, aunque respaldada por una capacidad de planificación efectiva y robusta tras esa mejora. Un refinamiento posterior (currículo de refuerzo y selección best-of-N en inferencia) elevó el éxito de pick-and-place end-to-end al 78 %, por encima del baseline supervisado del 60 %, con una plausibilidad de agarre del 82 % y de depósito del 92 % ($n = 50$, seed = 2026). Refuerza la capacidad de planificación efectiva del sistema sin tocar los umbrales estrictos de muestreo y multimodalidad sobre los que H2 se mantiene parcialmente aceptada. Un diagnóstico posterior de la cinemática inversa, cuyos fallos residuales resultaron ser de semilla del solver y no de alcanzabilidad, llevó la convergencia de IK al 100 % (frente al 76 % de la configuración best-of-N en idéntica semilla; la diferencia respecto al 90 % de la validación inicial se debe a que las trayectorias best-of-N presentan transiciones más amplias entre waypoints) y el éxito end-to-end al 84 %, lo que descarta ese factor como cuello de botella.

H3. Viabilidad sin GPU dedicada. Veredicto: aceptada. El ciclo end-to-end alcanza un p95 de 6.29 s en YCB-Video y 6.68 s en T-LESS ($n = 30$ por dataset), holgadamente por debajo del umbral de 10 s (margen superior a 3.32 s). El controlador PBVS converge en el 100 % de las muestras (50/50, mediana de 1.7 s). El profiling (exp10) reparte el ciclo así: 80.2 % a FoundationPose, 17.5 % a la simulación y 2.3 % a la difusión. La percepción es, pues, el único

cuello de botella relevante. La viabilidad se logra sobre una arquitectura híbrida local (Apple M1 Pro) y remota (Google Colab T4), cuyo coste (~1 920 USD) queda de uno a dos órdenes de magnitud por debajo del de los setups industriales (15 000–150 000 USD, Tabla 15).

Síntesis crítica y amenazas a la validez. Los tres contrastes confirman la tesis central, una integración FoundationPose + Diffusion Policy viable y reproducible en hardware accesible, sin sobre-afirmar: H1 reproduce el estado del arte, H3 demuestra que puede hacerse a bajo coste y H2 expone con honestidad el límite real (el conditioning como cuello de botella), resuelto en una iteración posterior mediante un encoder visual RGB-D que elevó la plausibilidad de agarre del 36 % al 78 %. Hay tres amenazas principales a la validez. De constructo: la validación local emplea AUC ADD-S, métrica relacionada pero no idéntica al Mean AR del leaderboard (L1). Externa: la evaluación se circunscribe a simulación (CoppeliaSim) y no incluye un brazo robótico real (L3). Interna: la diferencia de capacidad entre estimadores se mitiga empleando los checkpoints oficiales publicados. Queda la transferencia industrial. La licencia no comercial de FoundationPose (L5) restringe su uso directo en producción, así que una variante de licencia permisiva sería requisito para su explotación industrial. Un refinamiento posterior mediante currículo de refuerzo y selección best-of-N llevó el éxito end-to-end de pick-and-place al 78 % y, tras corregir la convergencia de cinemática inversa, al 84 %, lo que supera al baseline supervisado (60 %).

5.3. TRABAJO FUTURO

Como trabajo futuro se plantean las siguientes líneas:

- Integración de agentes LLM para planificación de alto nivel en bin picking complejo.
- Transferencia del pipeline a hardware real con cámaras Intel RealSense.
- Validación empírica de la portabilidad del pipeline a otros manipuladores serie (p. ej. Franka Panda, KUKA). La planificación opera en espacio de tarea y la cinemática inversa es genérica, dos rasgos que la favorecen; haría falta reconfigurar el robot y la escena y reentrenar la política sobre el nuevo espacio de trabajo.
- Entrenamiento con datos sintéticos mediante domain randomization en Isaac Sim.
- Extensión a estimación de pose de categoría (category-level) para generalizar a objetos no vistos.
- Optimización para inferencia en tiempo real en plataformas edge (NVIDIA Jetson).

- Validación del agarre físico real, ya que la simulación emplea snap+attach: modelos de contacto con verificación de sellado para ventosas de vacío integrados en simulador (Soraruf et al., 2025) o predicción de robustez para pinza paralela validada contra agarres físicos reales (Kim et al., 2022), junto con el escalado del ajuste fino por refuerzo en simuladores acelerados.
- Aceleración de la planificación mediante consistency/flow-matching (FlowPolicy, Zhang et al., 2024; ManiFlow, Yan et al., 2025), que generan acciones en uno o dos pasos de inferencia y recortan la latencia de muestreo (118 ms con DDIM-25) señalada como límite estricto de H2.

Las configuraciones pick-only tempranas arrastraban una limitación de depósito (0 % de deposit_plausible). Incorporar la fase de depósito la resolvió: se alcanzó un 92 % de plausibilidad de depósito y un 84 % de éxito end-to-end de pick-and-place.

5.4. APORTE E INNOVACIÓN DEL TRABAJO FIN DE MÁSTER

Esta sección formaliza el aporte original del Trabajo Fin de Máster. Lo separa de forma explícita de las contribuciones de los trabajos integrados (FoundationPose, Diffusion Policy, GDR-Net+ +) y lo sitúa como un trabajo de Ingeniería Matemática y Computación centrado en integración, formalización y reproducibilidad.

5.4.1. Aporte 1: Integración matemática unificada de dos paradigmas

El núcleo novedoso es la conexión formal entre el grupo de Lie $SE(3)$ que rige la pose 6-DoF estimada por FoundationPose y la ecuación diferencial estocástica que define el proceso de difusión inverso del módulo de planificación. La pose estimada $R \in SO(3)$, $t \in \mathbb{R}^3$ se proyecta a un vector de condicionamiento que alimenta la red ConditionalUNet1D del scheduler DDPM. La geometría diferencial de la percepción y la teoría de procesos estocásticos del muestreo de trayectorias comparten así un único formalismo. No se ha identificado en la literatura revisada una articulación previa de ambos formalismos para el dominio del bin picking.

5.4.2. Aporte 2: Reproducibilidad cuantitativa del estado del arte sin GPU dedicada

Los resultados publicados de FoundationPose y Diffusion Policy se obtuvieron en clusters GPU industriales, con costes de hardware que pueden superar los 10 000 USD por nodo. Aquí se demuestra lo contrario: sí cabe reproducir el estado del arte en pose estimation 6-DoF y entrenar un modelo de Diffusion Policy operativo usando solo Google Colab Free (GPU Tesla T4 compartida, 12 horas/día) y un MacBook Pro M1 Pro consumer. El coste total del entorno de cómputo queda por debajo de 2 000 USD, frente a las decenas de miles de un setup industrial. Esta democratización es un aporte verificable y útil para la comunidad investigadora de instituciones con presupuesto limitado.

5.4.3. Aporte 3: Rigor metodológico superior al estándar del área

El protocolo experimental de este trabajo se documenta con un detalle que la mayoría de publicaciones recientes de pose estimation ni siquiera reporta. Se declaran las variables independientes y dependientes sin ambigüedad, se justifica la métrica principal (AUC ADD-S, elegida por su robustez ante simetrías) y se trabaja sobre las particiones BOP-19 oficiales. La ejecución se hace con $n = 3$ semillas distintas. Los intervalos de confianza al 95 % salen de un bootstrap no paramétrico con $B = 1\,000$ resamples. El RUN_CARD se rastrea hasta el commit del repositorio, las dependencias Python quedan fijadas *lockfile* de forma bit-exacta y el

parámetro `n_diffusion_steps` pasa por una ablation formal con análisis del trade-off latencia/suavidad. Es un rigor propio de un trabajo de máster en Ingeniería Matemática y va más allá del estándar habitual en los papers de computer vision.

5.4.4. Aporte 4: Validación end-to-end con evidencia visual reproducible

La integración FoundationPose + Diffusion Policy no se queda en métricas offline. Se suma un experimento end-to-end ejecutado en CoppeliaSim Edu V4.10 con simulación física activa, sobre 30 instancias por dataset. El video MP4 resultante sirve como evidencia visual reproducible del pipeline en funcionamiento, y queda commiteado en el repositorio público junto a los scripts de grabación. Rara vez aparece este tipo de validación visual reproducible en la literatura del área. Lo normal es que los trabajos presenten únicamente métricas tabulares.

5.5.COMPARATIVA DE COSTES DE HARDWARE Y DEMOCRATIZACIÓN

Para sostener el aporte de democratización, se confronta el coste del entorno de cómputo de este TFM con el coste típico de los setups que producen los resultados publicados por los grupos industriales de NVIDIA o Stanford.

Tabla 15. Comparativa de costes de hardware para reproducir el estado del arte en pose estimation 6-DoF + planificación.

Fuente: Elaboración propia. Precios consultados a fecha 2026-05-10.

El coste relativo del setup TFM resulta aproximadamente un orden de magnitud inferior al setup industrial mínimo, y unos dos órdenes de magnitud por debajo de un setup de laboratorio con GPU de gama alta (p. ej. NVIDIA DGX). Reproducir resultados de la primera línea de investigación con este presupuesto no es trivial. Constituye, de hecho, una contribución metodológica en sí misma.

El contexto de mercado refuerza la pertinencia de un pipeline de bajo coste, más allá del contraste puntual de hardware. Firmas independientes de análisis de mercado estiman el mercado de sistemas de bin picking en torno a los 2 000 millones de USD en 2025, con una proyección a 7 300 millones para 2036 (CAGR del 12.5 %; FactMR, 2025); el de visión 3D industrial, su tecnología sensora habilitante, se sitúa entre 5 000 y 7 000 millones de USD, con tasas de crecimiento del 12–14 % anual (Grand View Research, 2024). Los costes lo confirman. Una cámara 3D de gama de entrada se adquiere por alrededor de 1 000 USD, mientras que

una celda industrial completa multiplica por aproximadamente tres el precio del robot. Eso ubica el presupuesto de este TFM (~1 920 USD) en el segmento de entrada. La adopción comercial es real y va a más: proveedores como Plus One Robotics superan los dos mil millones de operaciones de pick acumuladas (Plus One Robotics, 2026). Con todo, la barrera de madurez mejor documentada es que la autonomía total se considera todavía económicamente inviable y se recurre al esquema human-in-the-loop, lo que abre un nicho para pipelines reproducibles de bajo coste como prueba de concepto end-to-end. Conviene matizar el origen de estas cifras: proceden de informes de análisis de mercado, son estimaciones propietarias no revisadas por pares y divergen entre firmas, de modo que deben distinguirse del material de marketing de los fabricantes. Se citan como contexto orientativo, nunca como medición experimental propia.

5.6. ALCANCE Y LIMITACIONES DEL TRABAJO

Esta sección documenta el alcance y las limitaciones del trabajo presentado. La aportación se circunscribe a la integración matemática y experimental de los componentes utilizados. No sustituye las contribuciones originales de los trabajos referenciados ni constituye una participación oficial en los rankings absolutos de los benchmarks de la comunidad.

L1. Las métricas *Mean AR* (BOP) reportadas para FoundationPose y GDR-Net++ son las publicadas por los autores originales en sus papers o en el *leaderboard* oficial del BOP Challenge. La evaluación local complementaria emplea AUC ADD-S sobre el *subset* BOP-19, una métrica relacionada pero no idéntica al protocolo oficial. La integración con el toolkit BOP oficial en C++ queda abierta. Su compilación exige dependencias específicas de Linux que no están disponibles en el entorno macOS / Apple Silicon utilizado.

L2. El modelo Diffusion Policy entrenado en local lo es sobre un dataset sintético de trayectorias heurísticas ($n = 2\,000$ muestras generadas con un planificador determinista), y no sobre demostraciones humanas reales como en el paper original. De ahí que la cifra de mejora +46.9 % reportada por Chi et al. (2023) no se reproduzca ni se reclame. Lo que sí se demuestra es la viabilidad del entrenamiento end-to-end en MPS y la integración funcional con el resto del pipeline.

L3. La validación experimental se limita a simulación (CoppeliaSim Edu V4.10). No incluye experimentación con un brazo robótico real. La decisión es coherente con la titulación (máster

en Ingeniería Matemática y Computación, no robótica aplicada) y con los recursos disponibles. La transferencia sim-to-real queda señalada como línea de trabajo futuro.

L4. La evaluación con $n = 30$ instancias por dataset en el experimento E2E live basta para validar H3 con holgura. Un estudio de variabilidad completo con múltiples semillas (123, 2026) y bootstrap requeriría, en cambio, además una GPU T4 disponible 24×7, que excede el régimen de cuota Colab Free.

L5. La licencia no comercial de FoundationPose (NVIDIA NC) impide el uso directo en producción industrial. La validez del pipeline queda restringida a investigación y enseñanza, que es el dominio propio del TFM.

5.7.DELIMITACIÓN DEL ALCANCE

Esta sección acota el alcance del trabajo y complementa la sección anterior de aportes:

El trabajo no busca mejorar las métricas absolutas reportadas por Wen et al. (2024) en YCB-Video, T-LESS, LM-O, TUD-L, IC-BIN, ITODD ni HB. Esas métricas corresponden a la publicación original de FoundationPose y se usan como referencia bibliográfica, no como resultado propio del Trabajo Fin de Máster.

El trabajo no participa en la edición oficial del BOP Challenge 2024. Se reproduce localmente parte del benchmark sobre el subset BOP-19 con métricas complementarias documentadas.

El trabajo no compara su rendimiento con la mejora del 46.9 % reportada por Chi et al. (2023, Tabla 5) sobre el estado del arte previo en RoboMimic. El entrenamiento del modelo Diffusion Policy en local se hace sobre datos sintéticos heurísticos. Es una demostración de viabilidad del entrenamiento end-to-end en hardware accesible, no un resultado comparativo con el paper original.

El trabajo no propone una arquitectura nueva de red neuronal. Integra arquitecturas ya existentes y publicadas (FoundationPose y Diffusion Policy) sin tocar su diseño interno.

El trabajo no aporta un dataset nuevo. La evaluación se apoya en datasets BOP estándar (T-LESS, YCB-Video) y en trayectorias sintéticas heurísticas para el entrenamiento de Diffusion Policy.

La frontera entre aporte original e integración de trabajos previos enmarca la contribución del Trabajo Fin de Máster. La novedad está en la integración matemática formalizada, el rigor

metodológico aplicado, la reproducibilidad cuantitativa en hardware accesible y la validación end-to-end con evidencia experimental.

Componente	Setup industrial típico	Setup TFM (este trabajo)	Coste TFM
GPU principal	NVIDIA A100 80 GB	Google Colab Free (T4 compartida)	0 USD
GPU secundaria/local	NVIDIA RTX 4090	Apple M1 Pro (MPS)	~1 800 USD (laptop)
Almacenamiento datasets	2 TB NVMe enterprise	Google Drive 2 TB	120 USD/año
Servidor / cluster	DGX A100 (~150 k USD)	— (no aplica)	0 USD
Software	Licencias enterprise	OSS (PyTorch, FP MIT-NC, CoppeliaSim Edu)	0 USD
Coste total entorno	~15 000–150 000 USD	~1 920 USD	—

Referencias bibliográficas

Caraffa, A., Boscaini, D., & Poiesi, F. (2025). Accurate and efficient zero-shot 6D pose estimation with frozen foundation models [Preprint]. arXiv:2506.09784.

Chi, C., Xu, Z., Feng, S., Cousineau, E., Du, Y., Burchfiel, B., Tedrake, R., & Song, S. (2023). Diffusion Policy: Visuomotor policy learning via action diffusion. En *Robotics: Science and Systems (RSS)*. <https://arxiv.org/abs/2303.04137>

Cordeiro, A., Rocha, L. F., Boaventura-Cunha, J., Figueiredo, D., & Souza, J. P. (2026). A review of visual perception for robotic bin-picking. *Robotics and Autonomous Systems*, 196, 105236. <https://doi.org/10.1016/j.robot.2025.105236>

FactMR. (2025). Bin picking system market: Global industry analysis and forecast 2026–2036 [Informe de mercado]. <https://www.factmr.com/report/bin-picking-system-market>

Fang, H.-S., Wang, C., Gou, M., & Lu, C. (2020). GraspNet-1Billion: A large-scale benchmark for general object grasping. En *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. <https://doi.org/10.1109/CVPR.2020.00733>

- Godoy Bonillo, G., & Carrasco, J. M. (2026). pose6dof-transformers-diffusion: Estimación de pose 6-DoF mediante Transformers y modelos de difusión para bin picking robótico (Versión 0.1.0) [Software]. GitHub. <https://github.com/Giocrisrai/pose6dof-transformers-diffusion>
- Grand View Research. (2024). 3D machine vision market size, share & trends analysis report [Informe de mercado]. <https://www.grandviewresearch.com/industry-analysis/3d-machine-vision-market>
- Guan, B., Hao, Y., Wu, Q., Li, S., & Fang, Y. (2024). A survey of 6DoF object pose estimation methods for different application scenarios. *Sensors*, 24(4), 1076. <https://doi.org/10.3390/s24041076>
- Hagelskjær, F., & Buch, A. G. (2022). ParaPose: Parameter and domain randomization optimization for pose estimation using synthetic data. En *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*. <https://arxiv.org/abs/2203.00945>
- Ho, J., Jain, A., & Abbeel, P. (2020). Denoising diffusion probabilistic models. En *Advances in Neural Information Processing Systems (NeurIPS)*.
- Hodaň, T., Haluza, P., Obdržálek, Š., Matas, J., Lourakis, M., & Zabulis, X. (2017). T-LESS: An RGB-D dataset for 6D pose estimation of texture-less objects. En *IEEE Winter Conference on Applications of Computer Vision (WACV)*. <https://doi.org/10.1109/WACV.2017.103>
- Hodaň, T., Van Nguyen, N., Tyree, S., Guo, A., Fourmy, M., Labbé, Y., Sundermeyer, M., Wen, B., He, Y., Lee, J., Haluza, P., & Obdržálek, Š. (2025). BOP Challenge 2024 on model-based and model-free 6D object pose estimation [Preprint]. arXiv:2504.02812. <https://arxiv.org/abs/2504.02812>
- Huang, J., Liang, J., Hu, J., Sundermeyer, M., Yu, P. K. T., Navab, N., & Busam, B. (2025). XYZ-IBD: A high-precision bin-picking dataset for object 6D pose estimation [Preprint]. arXiv:2506.00599. <https://arxiv.org/abs/2506.00599>
- IndustryShapes (2026). IndustryShapes: An RGB-D benchmark dataset for 6D object pose estimation of industrial assembly components [Preprint]. arXiv:2602.05555. <https://arxiv.org/abs/2602.05555>

- Kim, C. M., Danielczuk, M., Huang, I., & Goldberg, K. (2022). IPC-GraspSim: Reducing the sim2real gap for parallel-jaw grasping with the incremental potential contact model. En *IEEE International Conference on Robotics and Automation (ICRA)*.
- Kleeberger, K., Bormann, R., Kraus, W., & Huber, M. F. (2020). A survey on learning-based robotic grasping. *Current Robotics Reports*, 1, 239–249. <https://doi.org/10.1007/s43154-020-00021-6>
- Konstantinou, C., Kampouroglou, N., Theodoris, N., Basamaklis, F., Gkournelos, C., & Makris, S. (2024). Leveraging generative AI for synthetic data generation: Improving 6-DOF pose estimation in assembly systems. En *Lecture Notes in Mechanical Engineering*. Springer. https://doi.org/10.1007/978-3-031-86489-6_8
- Labbé, Y., Manuelli, L., Mousavian, A., Tyree, S., Birchfield, S., Tremblay, J., Carpentier, J., Aubry, M., Fox, D., & Sivic, J. (2022). MegaPose: 6D pose estimation of novel objects via render & compare. En *Conference on Robot Learning (CoRL)*. <https://arxiv.org/abs/2212.06870>
- Li, Z., Chen, W., & Wang, S. (2025). Enhancing position-based visual servoing performance through transformer-based acceleration-level reinforcement learning. *Complex & Intelligent Systems*, 11. <https://doi.org/10.1007/s40747-025-02056-8>
- Liu, J., Sun, W., Yang, H., Zeng, Z., Liu, C., Zheng, J., Liu, X., Rahmani, H., Sebe, N., & Mian, A. (2025a). Deep learning-based object pose estimation: A comprehensive survey. *International Journal of Computer Vision*, 134. <https://doi.org/10.1007/s11263-025-02646-6>
- Liu, S., Xu, F., Wu, C., Chi, J., Yu, X., Wei, L., & Leng, C. (2024). CMT-6D: A lightweight iterative 6DoF pose estimation network based on cross-modal transformer. *The Visual Computer*, 41(3), 2011–2027. <https://doi.org/10.1007/s00371-024-03520-1>
- Liu, X., Zhang, R., Zhang, C., Wang, G., Tang, J., Li, Z., & Ji, X. (2025c). GDRNPP: A geometry-guided and fully learning-based object pose estimator. *IEEE Transactions on Pattern Analysis and Machine Intelligence*. <https://arxiv.org/abs/2102.12145>
- Liu, Y., Zhang, C., Dong, X., & Ning, J. (2025b). Point cloud-based deep learning in industrial production: A survey. *ACM Computing Surveys*, 57(7), 173. <https://doi.org/10.1145/3715851>

- Mo, N., Gan, W., Yokoya, N., & Chen, S. (2022). ES6D: A computation efficient and symmetry-aware 6D pose regression framework. En *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. <https://doi.org/10.1109/CVPR52688.2022.00660>
- Moon, S., Son, H., Hur, D., & Kim, S. (2024). GenFlow: Generalizable recurrent flow for 6D pose refinement of novel objects. En *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. <https://arxiv.org/abs/2403.11510>
- Murali, A., Eppner, C., Yang, X., Sundaralingam, B., & Huang, S. (2024). Automating smart pick-and-place with intrinsic flowstate and NVIDIA Isaac Manipulator [Blog técnico de empresa]. NVIDIA Technical Blog.
- NVIDIA (2024). Generating synthetic datasets with Isaac Sim Data Replicator [Blog técnico de empresa]. NVIDIA Developer Blog. <https://developer.nvidia.com/blog/generating-synthetic-datasets-isaac-sim-data-replicator/>
- Plus One Robotics. (2026). Plus One Robotics hits 2 billion picks [Noticia sectorial]. Robotics & Automation News. <https://www.roboticsandautomationnews.com/2026/04/09/plus-one-robotics-hits-2-billion-picks-as-warehouse-automation-scales-under-labor-pressure/100455/>
- Qi, C. R., Su, H., Mo, K., & Guibas, L. J. (2017a). PointNet: Deep learning on point sets for 3D classification and segmentation. En *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. <https://doi.org/10.1109/CVPR.2017.16>
- Qi, C. R., Yi, L., Su, H., & Guibas, L. J. (2017b). PointNet++: Deep hierarchical feature learning on point sets in a metric space. En *Advances in Neural Information Processing Systems (NeurIPS)*. <https://doi.org/10.5555/3295222.3295263>
- Ribeiro, E. G., Mendes, R. Q., & Grassi, V. (2021). Real-time deep learning approach to visual servo control and grasp detection for autonomous robotic manipulation. *Robotics and Autonomous Systems*, 139. <https://doi.org/10.1016/j.robot.2021.103757>
- Solà, J., Deray, J., & Atchuthan, D. (2018). A micro Lie theory for state estimation in robotics [Preprint]. arXiv:1812.01537. <https://arxiv.org/abs/1812.01537>

- Song, Y., Sohl-Dickstein, J., Kingma, D. P., Kumar, A., Ermon, S., & Poole, B. (2021). Score-based generative modeling through stochastic differential equations. En *International Conference on Learning Representations (ICLR)*.
- Soraruf, I., Todescato, M., Matt, D. T., & Giusti, A. (2025). Reducing the sim2real gap for vacuum grasping in Isaac Sim. En *IEEE International Conference on Simulation, Modeling, and Programming for Autonomous Robots (SIMPAP)*.
- Stuelpnagel, J. (1964). On the parametrization of the three-dimensional rotation group. *SIAM Review*, 6(4), 422–430.
- Sundermeyer, M., Hodaň, T., Labbé, Y., Wen, B., He, Y., Lee, J., Guo, A., Tyree, S., & Birchfield, S. (2024). BOP Challenge 2023 on detection, segmentation and pose estimation of seen and unseen rigid objects. En *IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*.
- Thalhammer, S., Bauer, D., Hönig, P., Weibel, J.-B., García-Rodríguez, J., & Vincze, M. (2024). Challenges for monocular 6-D object pose estimation in robotics. *IEEE Transactions on Robotics*. <https://doi.org/10.1109/TRO.2024.3433870>
- Tripicchio, P., D'Avella, S., & Avizzano, C. A. (2024). CEPB dataset: a photorealistic dataset to foster the research on bin picking in cluttered environments. *Frontiers in Robotics and AI*, 11. <https://doi.org/10.3389/frobt.2024.1222465>
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. En *Advances in Neural Information Processing Systems (NeurIPS)*.
- Wang, C., Xu, D., Zhu, Y., Martín-Martín, R., Lu, C., Fei-Fei, L., & Savarese, S. (2019). DenseFusion: 6D object pose estimation by iterative dense fusion. En *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. <https://arxiv.org/abs/1901.04780>
- Wang, G., Manhardt, F., Tombari, F., & Ji, X. (2021). GDR-Net: Geometry-guided direct regression network for monocular 6D object pose estimation. En *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*.

- Wen, B., Yang, W., Kautz, J., & Birchfield, S. (2024). FoundationPose: Unified 6D pose estimation and tracking of novel objects. En *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. <https://doi.org/10.1109/CVPR52733.2024.01692>
- Xiang, Y., Schmidt, T., Narayanan, V., & Fox, D. (2018). PoseCNN: A convolutional neural network for 6D object pose estimation in cluttered scenes. En *Robotics: Science and Systems (RSS)*. <https://doi.org/10.15607/RSS.2018.XIV.019>
- Xue, J., Gao, W., Wang, Y., Ji, C., Zhao, D., Yan, S., & Zhang, S. (2025). High-precision transformer-based visual servoing for humanoid robots in aligning tiny objects [Preprint]. arXiv:2503.04862. <https://arxiv.org/abs/2503.04862>
- Yan, G., Zhu, J., Deng, Y., Yang, S., Qiu, R.-Z., Cheng, X., Memmel, M., Krishna, R., Goyal, A., Wang, X., & Fox, D. (2025). ManiFlow: A general robot manipulation policy via consistency flow training. En *Conference on Robot Learning (CoRL)*.
- Zhang, Q., Liu, Z., Fan, H., Liu, G., Zeng, B., & Liu, S. (2024). FlowPolicy: Enabling fast and robust 3D flow-based policy via consistency flow matching for robot manipulation. En *AAAI Conference on Artificial Intelligence (AAAI, Oral)*. arXiv:2412.04987.
- Zhou, Y., Barnes, C., Lu, J., Yang, J., & Li, H. (2019). On the continuity of rotation representations in neural networks. En *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*.

Anexo A. Repositorio de código y reproducibilidad

El código fuente completo del proyecto, incluyendo los scripts de entrenamiento, evaluación y simulación, se encuentra disponible en un repositorio público de GitHub: <https://github.com/Giocrisrai/pose6dof-transformers-diffusion>. La estructura del repositorio sigue las mejores prácticas de organización de proyectos de investigación reproducible.

El repositorio incluye: (a) los scripts de configuración del entorno con Docker y conda; (b) los notebooks de entrenamiento y evaluación de FoundationPose; (c) la implementación de Diffusion Policy para generación de trayectorias; (d) los archivos de configuración de CoppeliaSim y ROS 2; (e) los scripts de generación de datos sintéticos y de simulación en CoppeliaSim; (f) la documentación completa de instalación y uso; (g) la suite de pruebas

unitarias (pytest) con integración continua en GitHub Actions; y (h) el paquete reutilizable bop-bootstrap-ci, publicado en PyPI, para el cálculo de los intervalos de confianza por bootstrap empleados en la evaluación.

Para garantizar la reproducibilidad de los experimentos, se proporcionan los archivos de configuración exactos (hiperparámetros, semillas aleatorias, versiones de dependencias) utilizados en cada experimento reportado en este trabajo. Las instrucciones detalladas de instalación y ejecución se encuentran en el archivo README.md del repositorio, que incluye además una imagen Docker con versiones congeladas (lockfile) y un archivo CITATION.cff para la cita del trabajo.

Comandos de reproducción

Para reproducir los resultados de este TFM, ejecutar la siguiente secuencia (las dependencias se instalan vía uv sync con el lockfile congelado).

```
# 1. Clonar repo y descargar assets desde Drive
git clone https://github.com/Giocrisrai/pose6dof-transformers-diffusion.git
cd pose6dof-transformers-diffusion
uv sync
python scripts/download_drive_assets.py --what all

# 2. Ejecutar evaluacion FP local con bootstrap CI 95%
python experiments/recompute_metrics_with_bootstrap.py --bootstrap-iters 1000

# 3. Entrenar Diffusion Policy en MPS (M1 Pro, ~5 min)
jupyter nbconvert --to notebook --execute
notebooks/06_diffusion_policy_training_LOCAL.ipynb

# 4. Ablation n_diffusion_steps {25, 50, 100}
python experiments/exp5_diffusion_steps_ablation.py

# 5. Pipeline E2E live con CoppeliaSim corriendo
open -a CoppeliaSim_Edu # lanzar CoppeliaSim Edu V4.10
python experiments/run_e2e_live.py --n-instances 30 --ddim-steps 25 --sim-steps
50

# 6. Grabar video evidencia
python experiments/record_e2e_video_v2.py --n-cycles 4 --fps 24

# 7. Consolidar figuras y resultados finales
python experiments/run_chapter6_consolidation.py
```

Estructura del repositorio

El repositorio adopta una organización habitual en proyectos de investigación reproducible. El código del pipeline vive en `src/`, repartido en `perception`, `planning`, `simulation` y `utils`. Los scripts ejecutables y sus salidas (JSON, PNG, MP4) están en `experiments/`, los cuadernos de Colab y locales en `notebooks/`, y las pruebas unitarias de `pytest` en `tests/`. Los datasets BOP descargados y los pesos congelados quedan bajo `data/` (excluidos por `.gitignore`). La memoria y el protocolo experimental viven en `docs/`, las utilidades como `download_drive_assets` en `scripts/`, y el Dockerfile de GPU para reproducir en clusters en `docker/`.

Trazabilidad de resultados

Cada cifra de la memoria puede rastrearse hasta un commit concreto y un run identificable. El RUN_CARD principal (`experiments/results/foundationpose_eval/RUN_CARD.md`) recoge el run del 2026-04-27, con commit `be02c8c`, hardware Tesla T4 y 1098+1012 instancias evaluadas. Los JSON de evidencia (`comparison_*.json`, `exp3_results.json`, `exp4_results.json`, `exp5_results.json`, `e2e_live_metrics.json`, `local_metrics_with_bootstrap.json`) están commiteados en `experiments/results/`. El video MP4 (`demo_v2.mp4`) y los frames-clave (`highlights_v2/`) se regeneran con `experiments/record_e2e_video_v2.py`.